DS GENERATOR

Laporan Analisis Data Deskriptif

Exploratory Data Analysis Report

Institut Teknologi Sains Bandung — Kelompok 2

DATASET	TOTAL DATA	STATUS	TANGGAL	ANALIS
ecommerce.txt	2,000 baris x 22 kolom	RAW DATA — Perlu Pembersihan	26 June 2026	Kelompok 2 ITSB

Auto-generated by DS Generator Platform

Kata Pengantar

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas segala berkat dan rahmat-Nya sehingga laporan analisis data ini dapat diselesaikan dengan baik. Laporan ini merupakan hasil analisis eksplorasi data (*Exploratory Data Analysis*) yang dilakukan secara otomatis menggunakan platform **DS Generator** — sistem analisis data deskriptif berbasis web yang dikembangkan oleh **Kelompok 2**, Program Studi Sains Data, Institut Teknologi Sains Bandung (ITSB).

Laporan ini menyajikan analisis menyeluruh terhadap dataset **ecommerce.txt** yang terdiri dari **2,000 baris observasi** dan **22 variabel**. Berdasarkan hasil pemindaian kualitas data yang dilakukan secara otomatis, dataset ini memerlukan proses pembersihan data lebih lanjut karena ditemukan 947 sel kosong dan 9 baris duplikat. Sebanyak 139 potensi outlier juga terdeteksi melalui metode IQR.

Laporan ini disusun dengan tujuan untuk memberikan gambaran komprehensif dan terstruktur mengenai karakteristik data, distribusi variabel, kualitas data, serta temuan-temuan penting yang dapat dijadikan dasar pengambilan keputusan berbasis data (*data-driven decision making*). Analisis yang disajikan meliputi statistik deskriptif, visualisasi distribusi, deteksi anomali, serta rekomendasi strategis yang dirumuskan secara otomatis berdasarkan pola data yang teridentifikasi.

Kami menyadari bahwa laporan ini masih memiliki keterbatasan, terutama dalam hal kedalaman analisis yang bergantung pada kelengkapan dan kualitas data yang diberikan. Oleh karena itu, saran dan masukan yang konstruktif sangat kami harapkan demi penyempurnaan di masa mendatang. Semoga laporan ini dapat memberikan nilai tambah yang signifikan bagi pembaca dan pihak-pihak yang memerlukan informasi dari dataset ini.

Cikarang, 26 June 2026

Tim Penyusun,

Kelompok 2 — Pemrograman Sains Data

Institut Teknologi Sains Bandung (ITSB)

Bab I — Pendahuluan & Latar Belakang

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mendorong munculnya ledakan data (*data explosion*) di berbagai sektor industri dan akademik. Kemampuan untuk memahami, mengolah, dan menginterpretasikan data secara efisien menjadi kompetensi krusial di era transformasi digital ini. Analisis data eksplorasi (*Exploratory Data Analysis* — EDA) merupakan langkah fundamental yang harus dilakukan sebelum pemodelan statistik atau machine learning, guna memahami karakteristik dasar dataset, mendeteksi anomali, dan merumuskan hipotesis awal yang akan diuji lebih lanjut.

Dataset **ecommerce.txt** yang dianalisis dalam laporan ini merupakan data dengan 2,000 observasi dan 22 variabel. Keberagaman variabel yang mencakup 7 variabel numerik dan 14 variabel kategorikal memberikan peluang analisis yang komprehensif untuk mengungkap pola tersembunyi dalam data.

1.2 Tujuan Analisis

- Mengidentifikasi karakteristik statistik dasar setiap variabel dalam dataset.
- Mendeteksi dan mengkuantifikasi masalah kualitas data (missing values, duplikat, outlier).
- Menganalisis distribusi dan pola sebaran data pada variabel numerik dan kategorikal.
- Menghasilkan visualisasi data yang informatif dan mudah dipahami.
- Merumuskan rekomendasi strategis berdasarkan temuan analisis.

1.3 Ruang Lingkup

Analisis dalam laporan ini mencakup: (1) pemeriksaan kualitas dan kesehatan data, (2) statistik deskriptif untuk seluruh variabel numerik dan kategorikal, (3) deteksi outlier menggunakan metode Interquartile Range (IQR), (4) analisis korelasi antar variabel numerik, serta (5) pembersihan data jika diperlukan. Analisis prediktif atau inferensial berada di luar ruang lingkup laporan ini.

1.4 Metodologi

Analisis dilakukan menggunakan platform **DS Generator** yang dibangun di atas ekosistem Python dengan library utama: **Pandas** untuk manipulasi data, **NumPy** untuk komputasi numerik, **Plotly** untuk visualisasi interaktif, **SciPy** untuk uji statistik, dan **ReportLab** untuk generasi laporan PDF. Proses analisis berjalan secara otomatis (*automated pipeline*) setelah dataset diunggah ke dalam sistem.

Bab II — Deskripsi & Ringkasan Dataset

2.1 Ringkasan Eksekutif

2,000	22	947	9	139
Total Baris	Total Kolom	Missing Values	Duplikat	IQR Outliers

Dataset **ecommerce.txt** terdiri dari **2,000 observasi** dengan **22 variabel**. Terdapat **947 sel kosong** (2.15% dari total data) yang tersebar di berbagai kolom. Sebanyak **9 baris duplikat** teridentifikasi dan perlu dihapus untuk menjaga integritas analisis. Deteksi outlier menggunakan metode IQR menemukan **139 potensi nilai ekstrem** yang perlu diverifikasi lebih lanjut.

2.2 Komposisi Variabel

Tipe Variabel	Jumlah	Contoh Variabel
Numerik (Kuantitatif)	7	unit_price, quantity, gross_sales, discount_pct ...
Kategorikal (Kualitatif)	14	order_date, ship_date, platform, category ...

Tabel 1. Komposisi variabel berdasarkan tipe data

Bab III — Kualitas Data & Data Health

3.1 Gambaran Umum Kualitas Data

Pemeriksaan kualitas data (*data quality assessment*) merupakan langkah krusial sebelum analisis statistik dilakukan. Pada tahap ini, setiap kolom diperiksa untuk mengidentifikasi sel kosong, nilai duplikat, inkonsistensi format, dan nilai ekstrem yang dapat mempengaruhi keakuratan analisis.

3.2 Detail Kualitas per Kolom

Kolom	Tipe	Missing	Unique	Outliers	Status
order_id	str	0 (0.0%)	1966	0	✓ OK
order_date	str	0 (0.0%)	1059	0	✓ OK
ship_date	str	200 (10.0%)	1040	0	■ Warning
platform	str	0 (0.0%)	21	0	✓ OK
category	str	0 (0.0%)	30	0	✓ OK
product_name	str	0 (0.0%)	49	0	✓ OK
unit_price	str	0 (0.0%)	1964	0	■ Warning
quantity	int64	0 (0.0%)	8	44	■ Warning
gross_sales	str	0 (0.0%)	1965	0	■ Warning
campaign	str	0 (0.0%)	5	0	✓ OK
voucher_code	str	49 (2.45%)	5	0	■ Warning
discount_pct	float64	69 (3.45%)	5	0	■ Warning
discount_value	str	0 (0.0%)	1306	0	✓ OK
shipping_cost	int64	0 (0.0%)	7	0	✓ OK
net_sales	str	0 (0.0%)	1816	0	✓ OK
payment_method	str	35 (1.75%)	28	0	■ Warning
customer_segment	str	0 (0.0%)	3	0	✓ OK
region	str	0 (0.0%)	8	0	✓ OK
stock_status	str	0 (0.0%)	3	0	✓ OK
order_status	str	0 (0.0%)	27	0	✓ OK
customer_rating	float64	406 (20.3%)	5	95	■ Warning
priority_flag	str	188 (9.4%)	6	0	■ Warning

Tabel 2. Ringkasan kualitas data per kolom

3.3 Peringatan Kualitas Data

Sistem mendeteksi sejumlah isu kualitas data yang perlu ditangani sebelum analisis lebih lanjut dilakukan:

- 9 baris duplikat ditemukan

- 139 outlier terdeteksi (metode IQR)
- 5 kolom memiliki inkonsistensi format teks
- 2 kolom kemungkinan tidak relevan (ID/free text)

Bab IV — Statistik Deskriptif — Variabel Numerik

4.1 Pengertian Statistik Deskriptif

Statistik deskriptif adalah cabang statistik yang bertujuan merangkum, mendeskripsikan, dan menyajikan data secara informatif tanpa menarik kesimpulan inferensial. Ukuran yang digunakan meliputi: **Mean** (rata-rata aritmatik), **Median** (nilai tengah), **Standar Deviasi** (ukuran dispersi/keragaman), **Nilai Minimum dan Maksimum** (rentang data), serta **Kuartil** (Q25 dan Q75) yang membagi data menjadi empat bagian sama besar.

4.2 Tabel Statistik Deskriptif

Kolom	Count	Missing	Mean	Median	Std Dev	Min	Q25	Q75	Max	Skewness
unit_price	—	—	565707.31	394476.5	519864.09	30827.0	—	—	2498385.0	1.7629
quantity	—	—	3.12	3.0	2.11	1.0	—	—	10.0	1.2395
gross_sales	—	—	1748582.2	987813.0	2316825.4	31646.0	—	—	22642020.0	3.6323
discount_pct	—	—	11.24	10.0	9.71	0.0	—	—	30.0	0.3452
discount_value	—	—	195657.34	68600.0	404870.68	0.0	—	—	6792606.0	7.0096
shipping_cost	—	—	14020.0	15000.0	7601.61	0.0	—	—	25000.0	-0.4739
net_sales	—	—	1308782.67	708293.0	2147465.74	-7663533.0	—	—	18080224.0	3.0803

Tabel 3. Statistik deskriptif variabel numerik

4.3 Interpretasi per Variabel

4.3.1 Variabel: unit_price

Variabel **unit_price** memiliki nilai rata-rata sebesar **565707.31** dengan nilai tengah (median) **394476.5**. Distribusi data miring ke kanan (*right-skewed*, skewness = 1.7629), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **30827.0** hingga **2498385.0** dengan standar deviasi **519864.09**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.2 Variabel: quantity

Variabel **quantity** memiliki nilai rata-rata sebesar **3.12** dengan nilai tengah (median) **3.0**. Distribusi data miring ke kanan (*right-skewed*, skewness = 1.2395), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **1.0** hingga **10.0** dengan standar deviasi **2.11**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.3 Variabel: gross_sales

Variabel **gross_sales** memiliki nilai rata-rata sebesar **1748582.2** dengan nilai tengah (median) **987813.0**. Distribusi data miring ke kanan (*right-skewed*, skewness = 3.6323), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **31646.0** hingga **22642020.0** dengan standar deviasi **2316825.4**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.4 Variabel: discount_pct

Variabel **discount_pct** memiliki nilai rata-rata sebesar **11.24** dengan nilai tengah (median) **10.0**. Distribusi data cenderung simetris (|skewness| < 0,5), mengindikasikan data mendekati distribusi normal. Rentang nilai berkisar antara **0.0** hingga **30.0** dengan standar deviasi **9.71**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.5 Variabel: discount_value

Variabel **discount_value** memiliki nilai rata-rata sebesar **195657.34** dengan nilai tengah (median) **68600.0**. Distribusi data miring ke kanan (*right-skewed*, skewness = 7.0096), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **0.0** hingga **6792606.0** dengan standar deviasi **404870.68**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.6 Variabel: shipping_cost

Variabel **shipping_cost** memiliki nilai rata-rata sebesar **14020.0** dengan nilai tengah (median) **15000.0**. Distribusi data cenderung simetris (|skewness| < 0,5), mengindikasikan data mendekati distribusi normal. Rentang nilai berkisar antara **0.0** hingga **25000.0** dengan standar deviasi **7601.61**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.7 Variabel: net_sales

Variabel **net_sales** memiliki nilai rata-rata sebesar **1308782.67** dengan nilai tengah (median) **708293.0**. Distribusi data miring ke kanan (*right-skewed*, skewness = 3.0803), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **-7663533.0** hingga **18080224.0** dengan standar deviasi **2147465.74**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

Bab V — Statistik Deskriptif — Variabel Kategorikal

5.1 Pengertian Variabel Kategorikal

Variabel kategorikal adalah variabel yang nilainya berupa kategori atau label, bukan angka kontinu. Terdapat dua jenis utama: variabel **nominal** (kategori tanpa urutan, misal: jenis kelamin, kota) dan variabel **ordinal** (kategori berurutan, misal: tingkat kepuasan, kelas nilai). Analisis variabel kategorikal berfokus pada frekuensi kemunculan setiap kategori dan distribusi proporsionalnya.

5.2 Tabel Statistik Kategorikal

Kolom	Unique	Mode (Dominan)	Frekuensi Mode	Mode %	Missing
order_date	1059	2024-09-29	6	0.3%	0
ship_date	1040	28/07/2024	7	0.39%	200
platform	21	Shopee	379	18.95%	0
category	30	Fashion	366	18.3%	0
product_name	49	Storage Box	96	4.8%	0
campaign	5	Normal Day	673	33.65%	0
voucher_code	5	NONE	658	33.73%	49
payment_method	28	Virtual Account	371	18.88%	35
customer_segment	3	Returning	1089	54.45%	0
region	8	Bandung	271	13.55%	0
stock_status	3	In Stock	1465	73.25%	0
order_status	27	DELIVERED	396	19.8%	0
customer_rating	5	5.0	820	51.44%	406
priority_flag	6	No	489	26.99%	188

Tabel 4. Statistik deskriptif variabel kategorikal

5.3 Interpretasi per Variabel

5.3.1 Variabel: order_date

Variabel kategorikal **order_date** memiliki **1059 kategori unik**. Kategori yang paling dominan adalah "**2024-09-29**" dengan frekuensi kemunculan sebesar **0.3%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding.

5.3.2 Variabel: ship_date

Variabel kategorikal **ship_date** memiliki **1040 kategori unik**. Kategori yang paling dominan adalah "**28/07/2024**" dengan frekuensi kemunculan sebesar **0.39%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding. Terdapat **200 nilai kosong** yang perlu diperhatikan dalam proses preprocessing.

5.3.3 Variabel: platform

Variabel kategorikal **platform** memiliki **21 kategori unik**. Kategori yang paling dominan adalah "**Shopee**" dengan frekuensi kemunculan sebesar **18.95%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding.

5.3.4 Variabel: category

Variabel kategorikal **category** memiliki **30 kategori unik**. Kategori yang paling dominan adalah "**Fashion**" dengan frekuensi kemunculan sebesar **18.3%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding.

5.3.5 Variabel: product_name

Variabel kategorikal **product_name** memiliki **49 kategori unik**. Kategori yang paling dominan adalah "**Storage Box**" dengan frekuensi kemunculan sebesar **4.8%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding.

5.3.6 Variabel: campaign

Variabel kategorikal **campaign** memiliki **5 kategori unik**. Kategori yang paling dominan adalah "**Normal Day**" dengan frekuensi kemunculan sebesar **33.65%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation.

5.3.7 Variabel: voucher_code

Variabel kategorikal **voucher_code** memiliki **5 kategori unik**. Kategori yang paling dominan adalah "**NONE**" dengan frekuensi kemunculan sebesar **33.73%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation. Terdapat **49 nilai kosong** yang perlu diperhatikan dalam proses preprocessing.

5.3.8 Variabel: payment_method

Variabel kategorikal **payment_method** memiliki **28 kategori unik**. Kategori yang paling dominan adalah "**Virtual Account**" dengan frekuensi kemunculan sebesar **18.88%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding. Terdapat **35 nilai kosong** yang perlu diperhatikan dalam proses preprocessing.

5.3.9 Variabel: customer_segment

Variabel kategorikal **customer_segment** memiliki **3 kategori unik**. Kategori yang paling dominan adalah "**Returning**" dengan frekuensi kemunculan sebesar **54.45%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation.

5.3.10 Variabel: region

Variabel kategorikal **region** memiliki **8 kategori unik**. Kategori yang paling dominan adalah "**Bandung**" dengan frekuensi kemunculan sebesar **13.55%%** dari total data. Variabel ini memiliki jumlah kategori yang moderat, berpotensi untuk dijadikan fitur dalam pemodelan machine learning setelah encoding.

5.3.11 Variabel: stock_status

Variabel kategorikal **stock_status** memiliki **3 kategori unik**. Kategori yang paling dominan adalah "**In Stock**" dengan frekuensi kemunculan sebesar **73.25%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation.

5.3.12 Variabel: order_status

Variabel kategorikal **order_status** memiliki **27 kategori unik**. Kategori yang paling dominan adalah "**DELIVERED**" dengan frekuensi kemunculan sebesar **19.8%%** dari total data. Variabel ini memiliki kardinalitas tinggi (banyak kategori unik), disarankan untuk dikelompokkan atau di-encode dengan teknik target encoding.

5.3.13 Variabel: customer_rating

Variabel kategorikal **customer_rating** memiliki **5 kategori unik**. Kategori yang paling dominan adalah "**5.0**" dengan frekuensi kemunculan sebesar **51.44%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation. Terdapat **406 nilai kosong** yang perlu diperhatikan dalam proses preprocessing.

5.3.14 Variabel: priority_flag

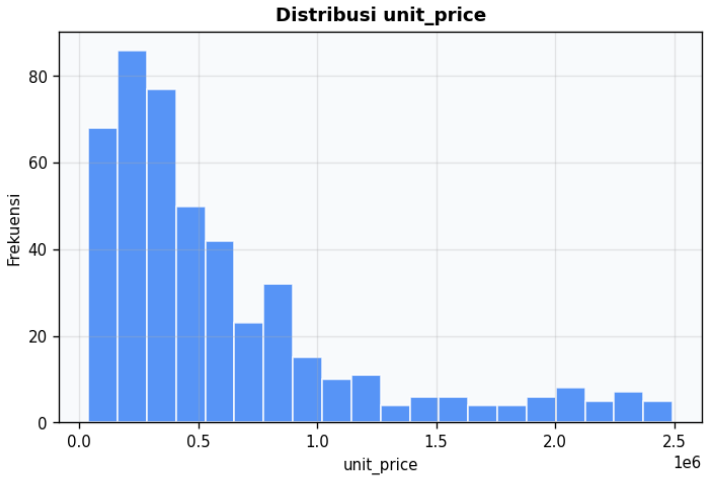
Variabel kategorikal **priority_flag** memiliki **6 kategori unik**. Kategori yang paling dominan adalah "**No**" dengan frekuensi kemunculan sebesar **26.99%%** dari total data. Variabel ini memiliki jumlah kategori yang moderat, berpotensi untuk dijadikan fitur dalam pemodelan machine learning setelah encoding. Terdapat **188 nilai kosong** yang perlu diperhatikan dalam proses preprocessing.

Bab VI — Visualisasi Data & Interpretasi

6.1 Pentingnya Visualisasi dalam EDA

Visualisasi data merupakan komponen esensial dalam EDA karena memungkinkan analis untuk memahami pola, tren, distribusi, dan anomali dalam data secara intuitif dan efisien. Berikut adalah visualisasi yang dihasilkan berdasarkan karakteristik dataset ini.

6.2 Distribusi Frekuensi — unit_price

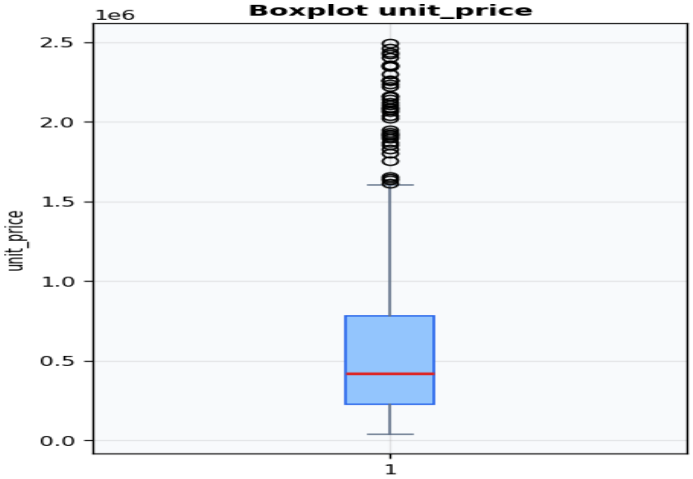


Gambar 1. Distribusi Frekuensi — unit_price

Interpretasi

Variabel **unit_price** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 1.7629) dengan rata-rata 565707.31.

6.3 Boxplot — unit_price

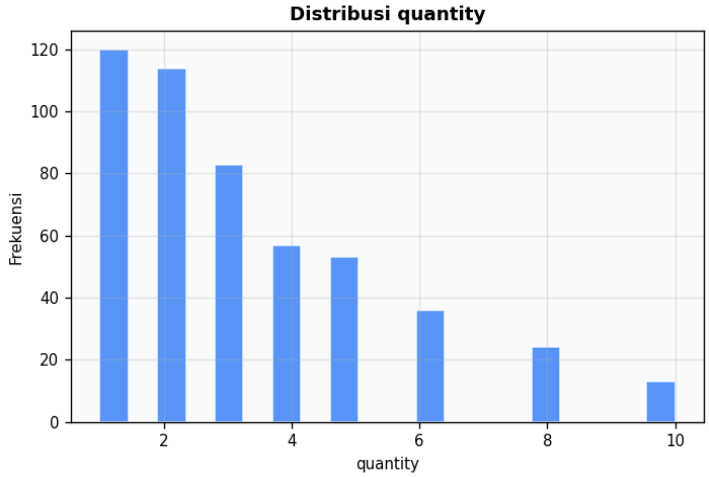


Gambar 2. Boxplot — unit_price

Interpretasi

Boxplot **unit_price** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.4 Distribusi Frekuensi — quantity

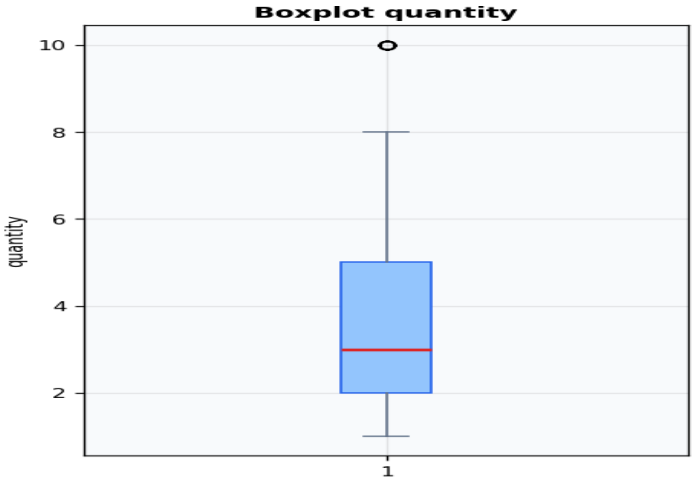


Gambar 3. Distribusi Frekuensi — quantity

Interpretasi

Variabel **quantity** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 1.2395) dengan rata-rata 3.12.

6.5 Boxplot — quantity

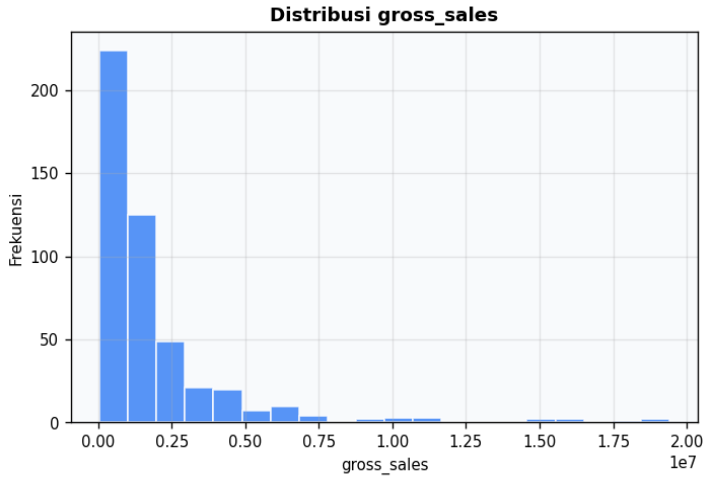


Gambar 4. Boxplot — quantity

Interpretasi

Boxplot **quantity** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.6 Distribusi Frekuensi — gross_sales

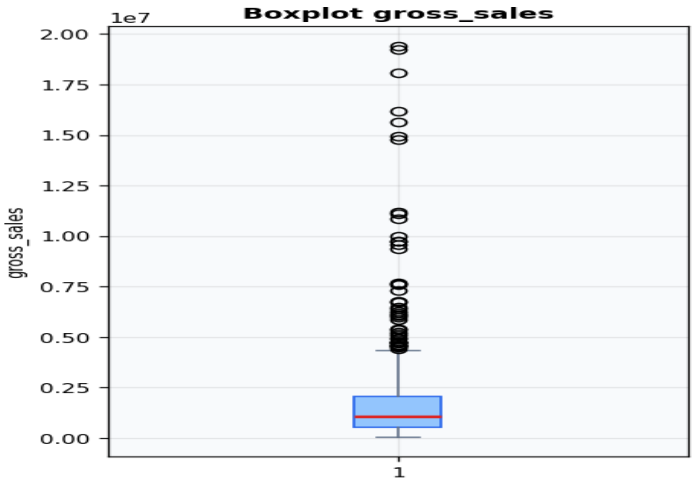


Gambar 5. Distribusi Frekuensi — gross_sales

Interpretasi

Variabel **gross_sales** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 3.6323) dengan rata-rata 1748582.2.

6.7 Boxplot — gross_sales

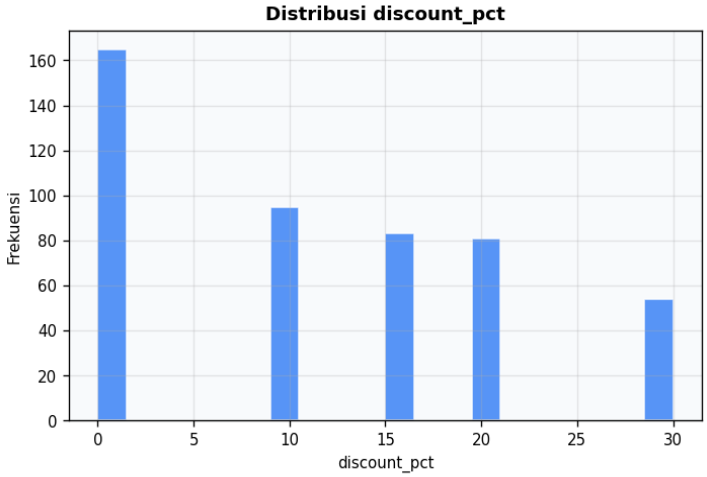


Gambar 6. Boxplot — gross_sales

Interpretasi

Boxplot **gross_sales** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.8 Distribusi Frekuensi — discount_pct

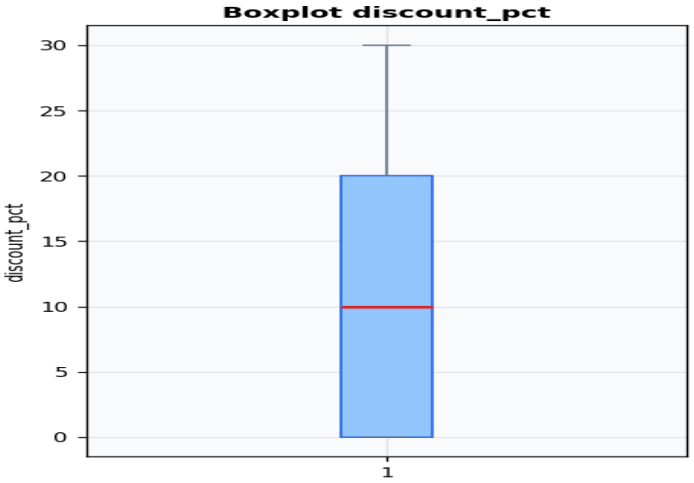


Gambar 7. Distribusi Frekuensi — discount_pct

Interpretasi

Variabel **discount_pct** menunjukkan distribusi cenderung simetris (skewness = 0.3452) dengan rata-rata 11.24.

6.9 Boxplot — discount_pct

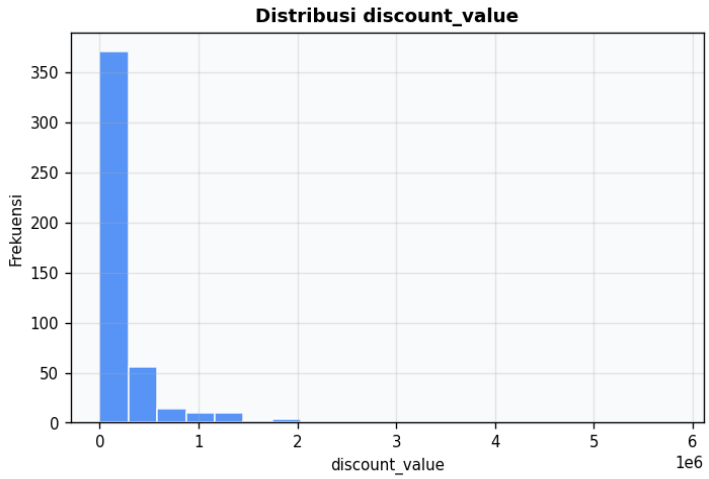


Gambar 8. Boxplot — discount_pct

Interpretasi

Boxplot **discount_pct** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.10 Distribusi Frekuensi — discount_value

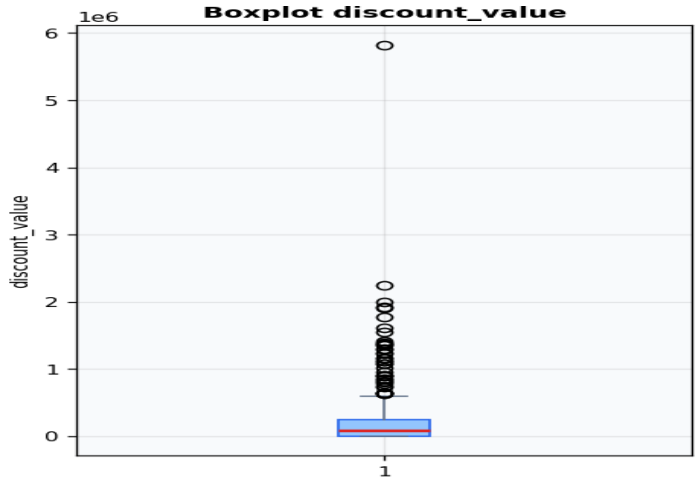


Gambar 9. Distribusi Frekuensi — discount_value

Interpretasi

Variabel **discount_value** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 7.0096) dengan rata-rata 195657.34.

6.11 Boxplot — discount_value

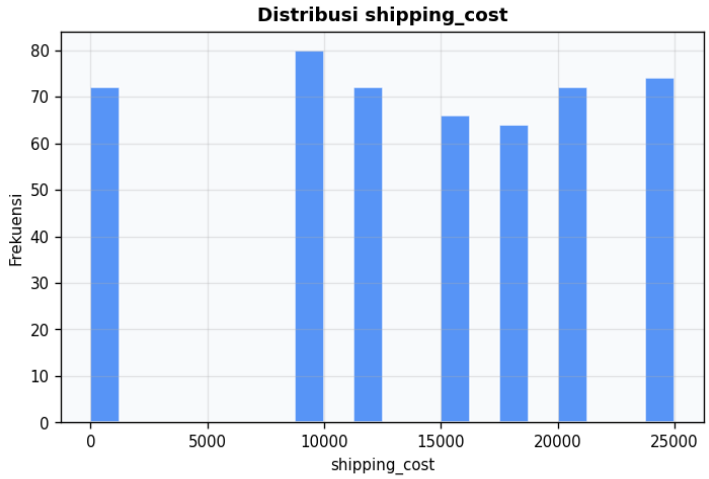


Gambar 10. Boxplot — discount_value

Interpretasi

Boxplot **discount_value** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.12 Distribusi Frekuensi — shipping_cost

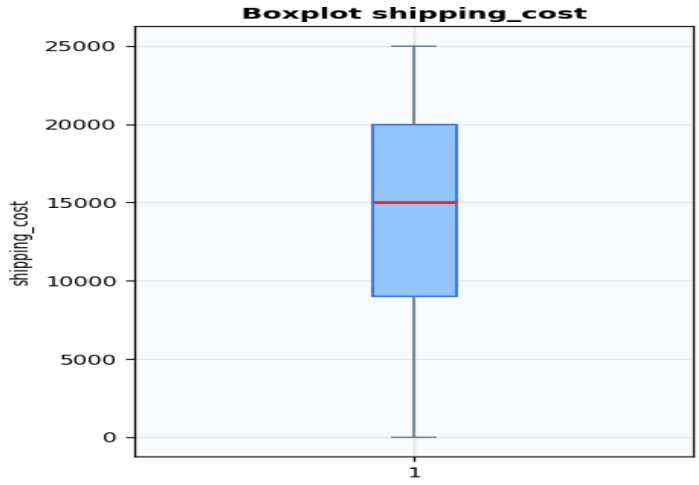


Gambar 11. Distribusi Frekuensi — shipping_cost

Interpretasi

Variabel **shipping_cost** menunjukkan distribusi cenderung simetris (skewness = -0.4739) dengan rata-rata 14020.0.

6.13 Boxplot — shipping_cost

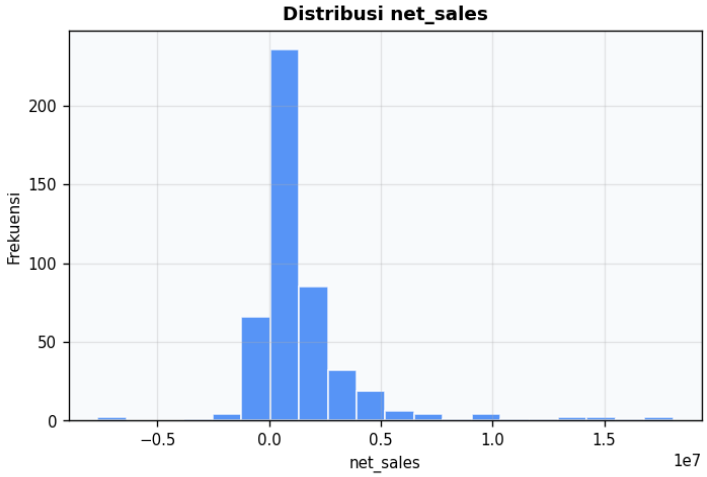


Gambar 12. Boxplot — shipping_cost

Interpretasi

Boxplot **shipping_cost** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.14 Distribusi Frekuensi — net_sales

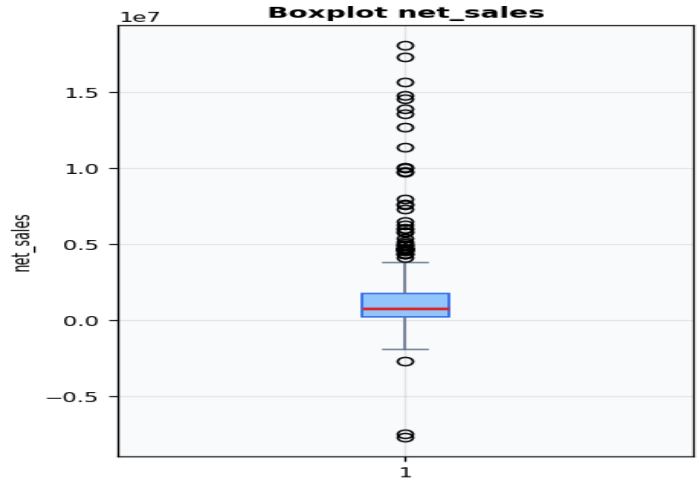


Gambar 13. Distribusi Frekuensi — net_sales

Interpretasi

Variabel **net_sales** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 3.0803) dengan rata-rata 1308782.67.

6.15 Boxplot — net_sales

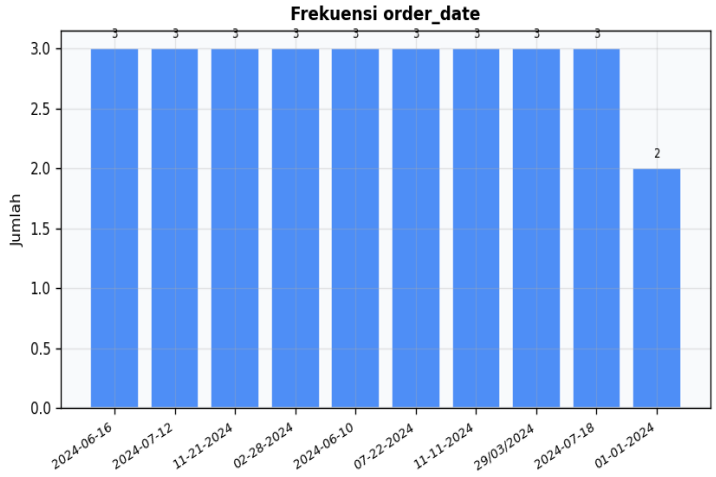


Gambar 14. Boxplot — net_sales

Interpretasi

Boxplot **net_sales** menunjukkan sebaran interkuartil (Q25 = ?, Q75 = ?) dengan potensi outlier yang ditandai titik di luar whisker.

6.16 Frekuensi Kategori — order_date

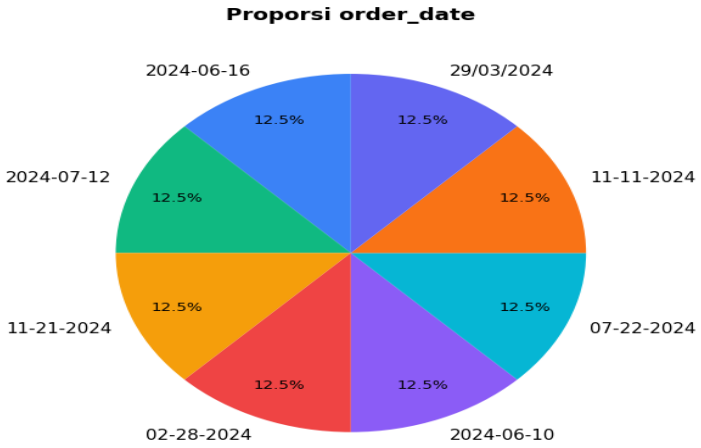


Gambar 15. Frekuensi Kategori — order_date

Interpretasi

Variabel **order_date** memiliki 1059 kategori unik. Kategori terdominan adalah "2024-09-29" dengan proporsi 0.3%.

6.17 Proporsi Kategori — order_date

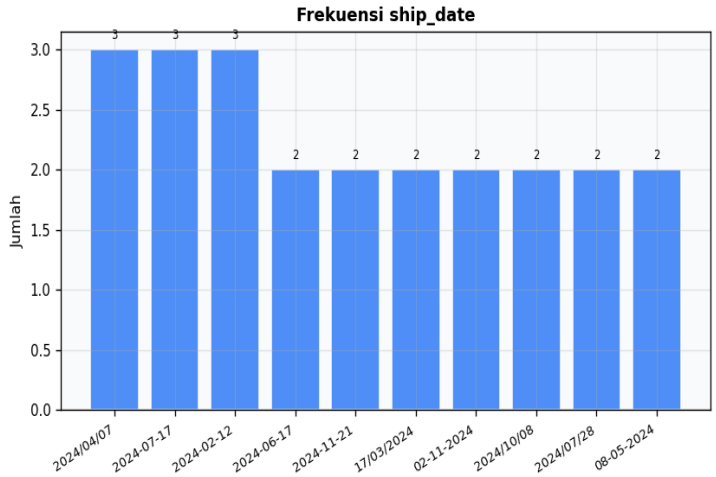


Gambar 16. Proporsi Kategori — order_date

Interpretasi

Pie chart **order_date** menunjukkan proporsi relatif dari 1059 kategori. Kategori "2024-09-29" mendominasi dengan 0.3% dari keseluruhan data.

6.18 Frekuensi Kategori — ship_date

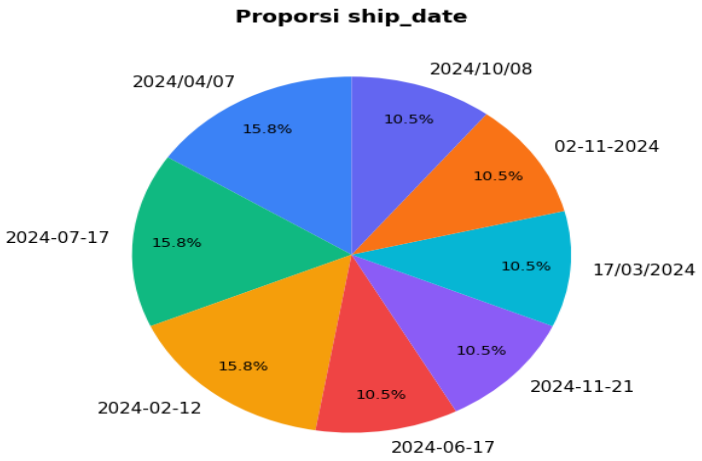


Gambar 17. Frekuensi Kategori — ship_date

Interpretasi

Variabel **ship_date** memiliki 1040 kategori unik. Kategori terdominan adalah "28/07/2024" dengan proporsi 0.39%.

6.19 Proporsi Kategori — ship_date

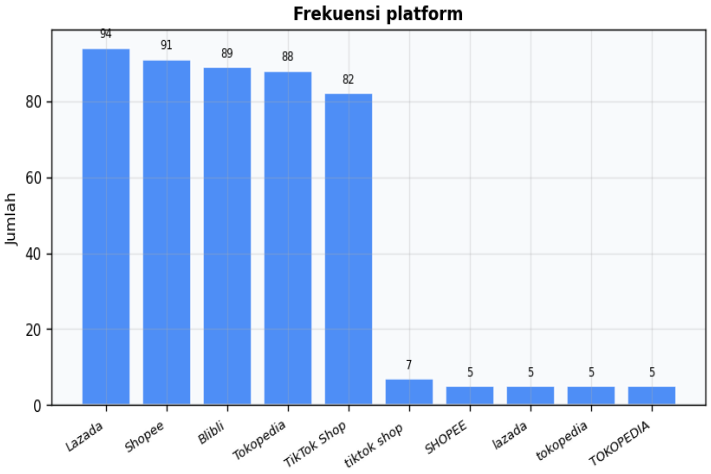


Gambar 18. Proporsi Kategori — ship_date

Interpretasi

Pie chart **ship_date** menunjukkan proporsi relatif dari 1040 kategori. Kategori "28/07/2024" mendominasi dengan 0.39% dari keseluruhan data.

6.20 Frekuensi Kategori — platform

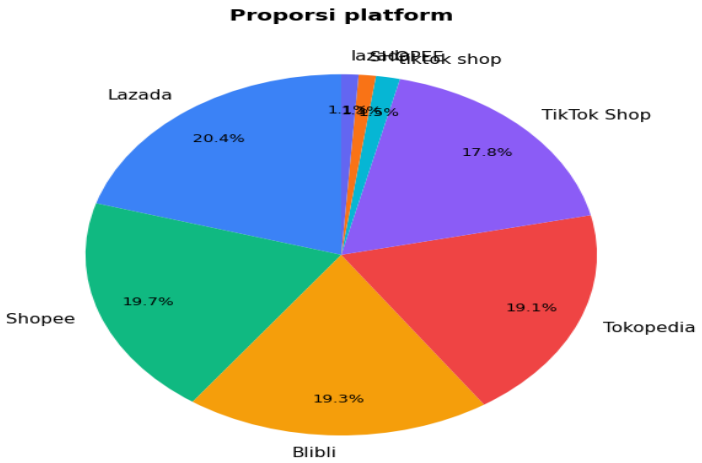


Gambar 19. Frekuensi Kategori — platform

Interpretasi

Variabel **platform** memiliki 21 kategori unik. Kategori terdominan adalah "Shopee" dengan proporsi 18.95%.

6.21 Proporsi Kategori — platform

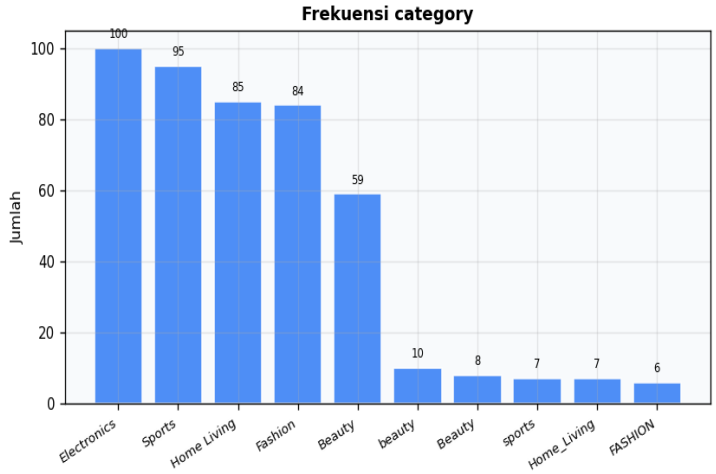


Gambar 20. Proporsi Kategori — platform

Interpretasi

Pie chart **platform** menunjukkan proporsi relatif dari 21 kategori. Kategori "Shopee" mendominasi dengan 18.95% dari keseluruhan data.

6.22 Frekuensi Kategori — category

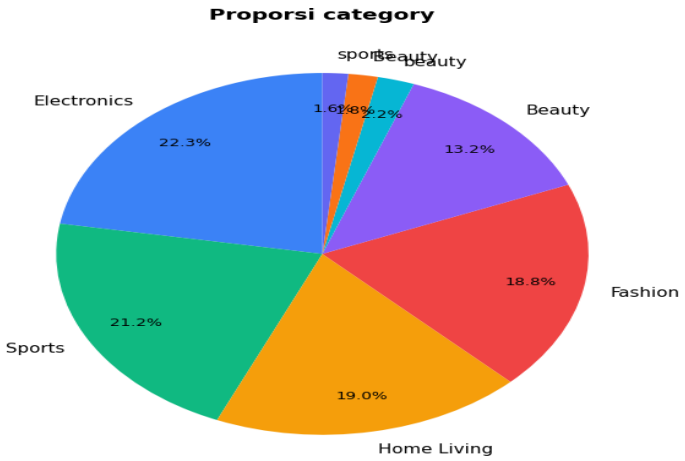


Gambar 21. Frekuensi Kategori — category

Interpretasi

Variabel **category** memiliki 30 kategori unik. Kategori terdominan adalah "Fashion" dengan proporsi 18.3%.

6.23 Proporsi Kategori — category

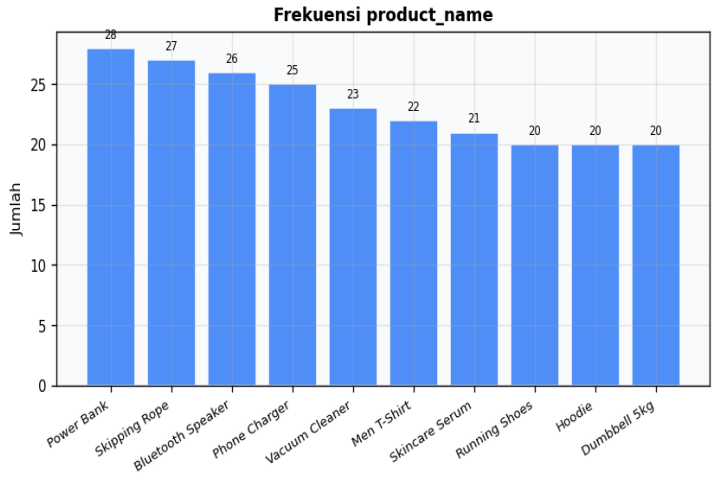


Gambar 22. Proporsi Kategori — category

Interpretasi

Pie chart **category** menunjukkan proporsi relatif dari 30 kategori. Kategori "Fashion" mendominasi dengan 18.3% dari keseluruhan data.

6.24 Frekuensi Kategori — product_name

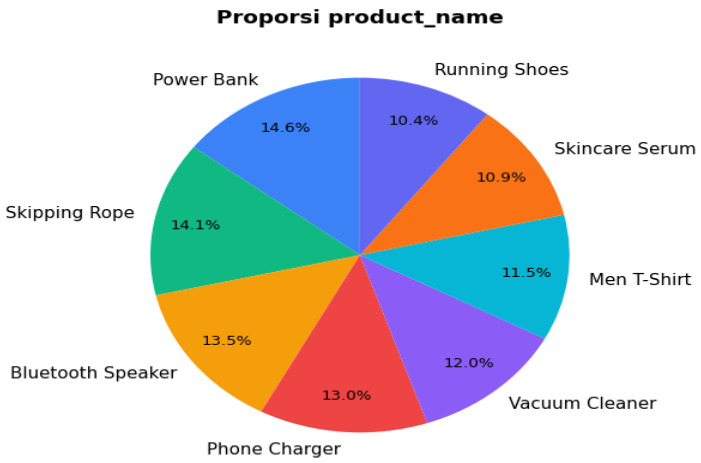


Gambar 23. Frekuensi Kategori — product_name

Interpretasi

Variabel **product_name** memiliki 49 kategori unik. Kategori terdominan adalah "Storage Box" dengan proporsi 4.8%.

6.25 Proporsi Kategori — product_name

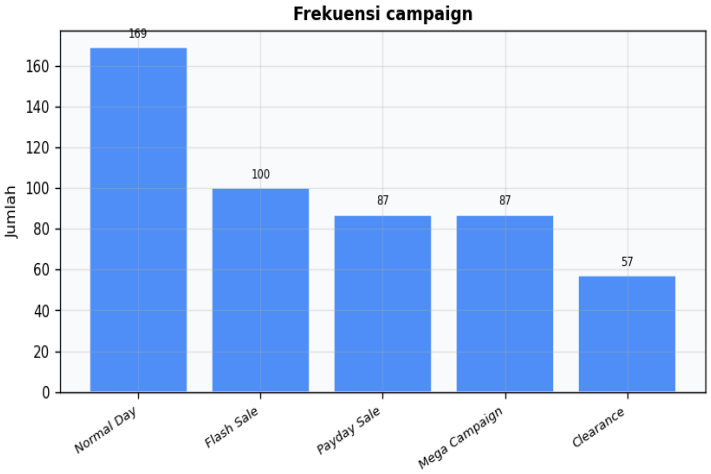


Gambar 24. Proporsi Kategori — product_name

Interpretasi

Pie chart **product_name** menunjukkan proporsi relatif dari 49 kategori. Kategori "Storage Box" mendominasi dengan 4.8% dari keseluruhan data.

6.26 Frekuensi Kategori — campaign



Gambar 25. Frekuensi Kategori — campaign

Interpretasi

Variabel **campaign** memiliki 5 kategori unik. Kategori terdominan adalah "Normal Day" dengan proporsi 33.65%.

6.27 Proporsi Kategori — campaign

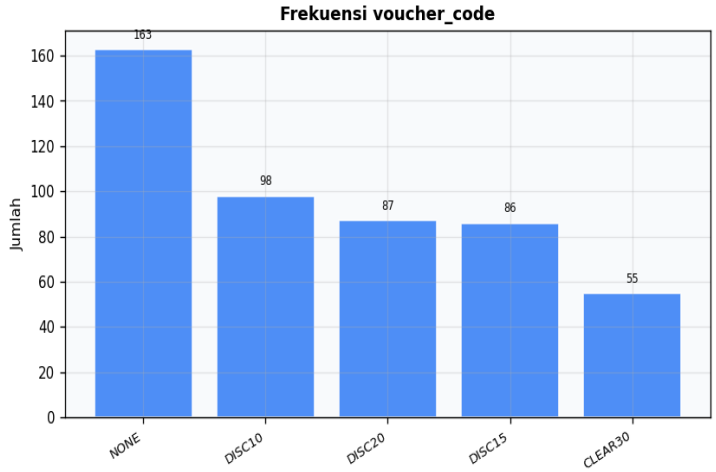


Gambar 26. Proporsi Kategori — campaign

Interpretasi

Pie chart **campaign** menunjukkan proporsi relatif dari 5 kategori. Kategori "Normal Day" mendominasi dengan 33.65% dari keseluruhan data.

6.28 Frekuensi Kategori — voucher_code

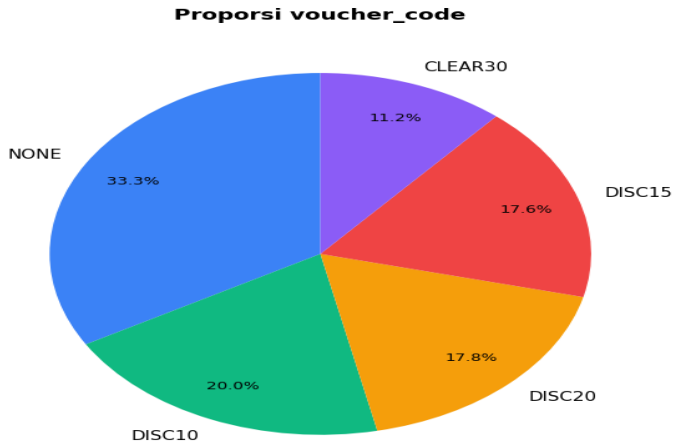


Gambar 27. Frekuensi Kategori — voucher_code

Interpretasi

Variabel **voucher_code** memiliki 5 kategori unik. Kategori terdominan adalah "NONE" dengan proporsi 33.73%.

6.29 Proporsi Kategori — voucher_code

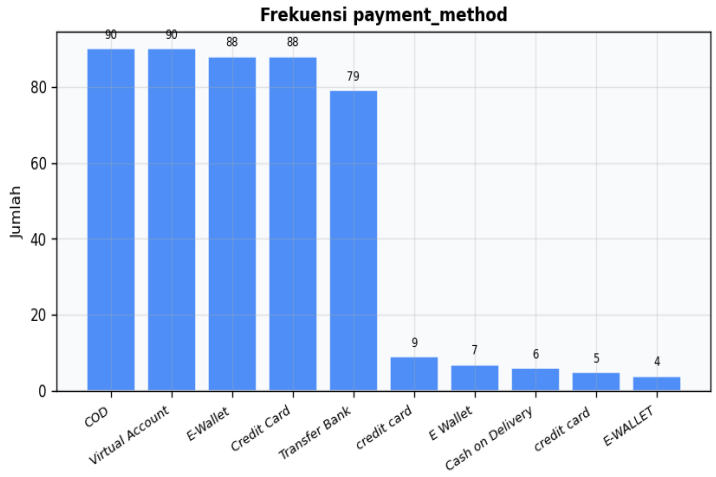


Gambar 28. Proporsi Kategori — voucher_code

Interpretasi

Pie chart **voucher_code** menunjukkan proporsi relatif dari 5 kategori. Kategori "NONE" mendominasi dengan 33.73% dari keseluruhan data.

6.30 Frekuensi Kategori — payment_method

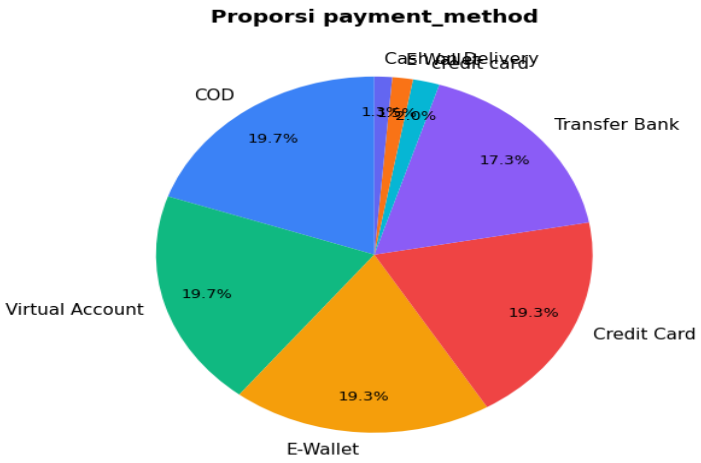


Gambar 29. Frekuensi Kategori — payment_method

Interpretasi

Variabel **payment_method** memiliki 28 kategori unik. Kategori terdominan adalah "Virtual Account" dengan proporsi 18.88%.

6.31 Proporsi Kategori — payment_method

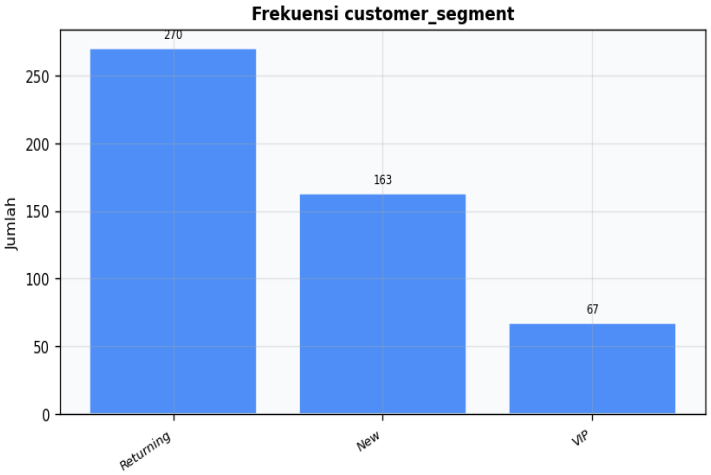


Gambar 30. Proporsi Kategori — payment_method

Interpretasi

Pie chart **payment_method** menunjukkan proporsi relatif dari 28 kategori. Kategori "Virtual Account" mendominasi dengan 18.88% dari keseluruhan data.

6.32 Frekuensi Kategori — customer_segment

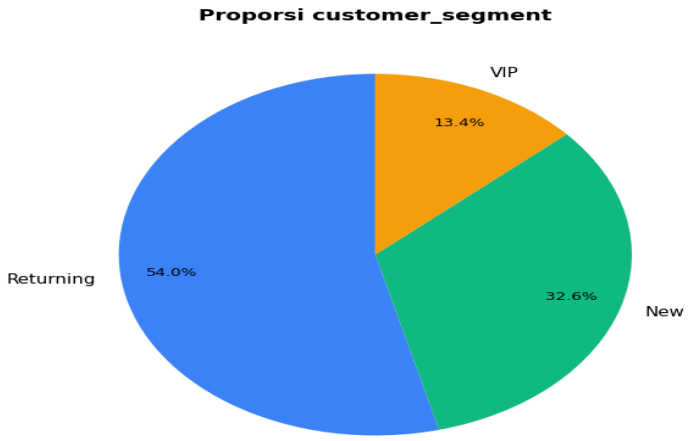


Gambar 31. Frekuensi Kategori — customer_segment

Interpretasi

Variabel **customer_segment** memiliki 3 kategori unik. Kategori terdominan adalah "Returning" dengan proporsi 54.45%.

6.33 Proporsi Kategori — customer_segment

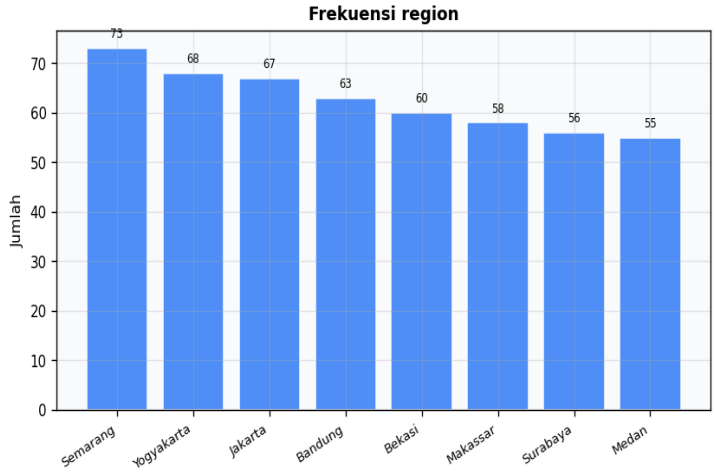


Gambar 32. Proporsi Kategori — customer_segment

Interpretasi

Pie chart **customer_segment** menunjukkan proporsi relatif dari 3 kategori. Kategori "Returning" mendominasi dengan 54.45% dari keseluruhan data.

6.34 Frekuensi Kategori — region



Gambar 33. Frekuensi Kategori — region

Interpretasi

Variabel **region** memiliki 8 kategori unik. Kategori terdominan adalah "Bandung" dengan proporsi 13.55%.

6.35 Proporsi Kategori — region

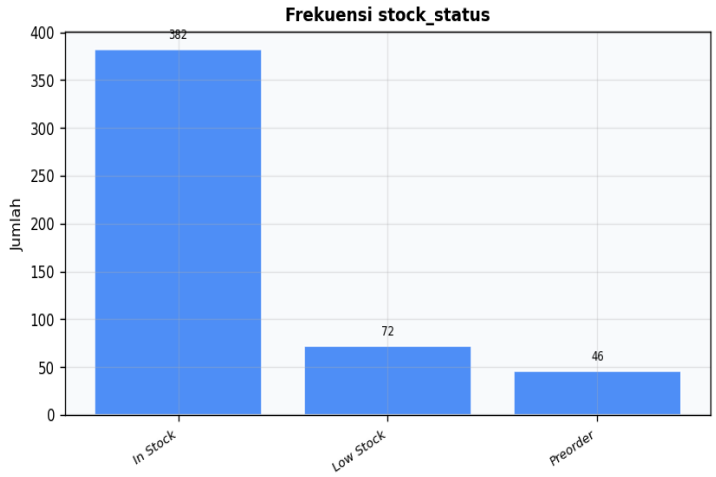


Gambar 34. Proporsi Kategori — region

Interpretasi

Pie chart **region** menunjukkan proporsi relatif dari 8 kategori. Kategori "Bandung" mendominasi dengan 13.55% dari keseluruhan data.

6.36 Frekuensi Kategori — stock_status

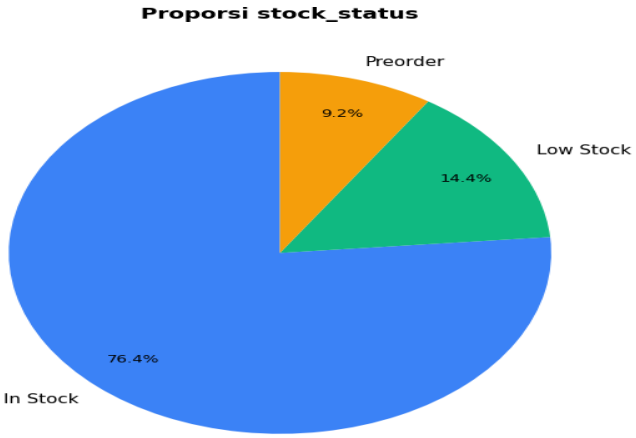


Gambar 35. Frekuensi Kategori — stock_status

Interpretasi

Variabel **stock_status** memiliki 3 kategori unik. Kategori terdominan adalah "In Stock" dengan proporsi 73.25%.

6.37 Proporsi Kategori — stock_status

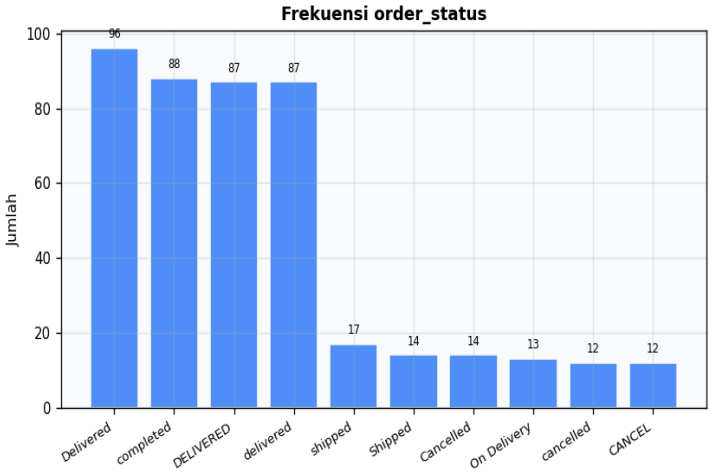


Gambar 36. Proporsi Kategori — stock_status

Interpretasi

Pie chart **stock_status** menunjukkan proporsi relatif dari 3 kategori. Kategori "In Stock" mendominasi dengan 73.25% dari keseluruhan data.

6.38 Frekuensi Kategori — order_status

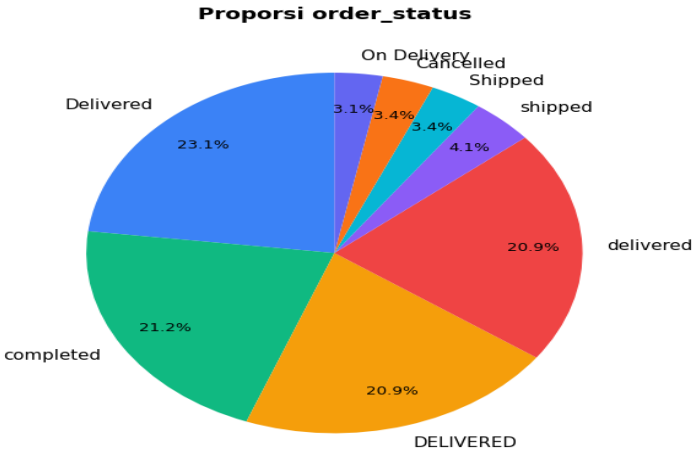


Gambar 37. Frekuensi Kategori — order_status

Interpretasi

Variabel **order_status** memiliki 27 kategori unik. Kategori terdominan adalah "DELIVERED" dengan proporsi 19.8%.

6.39 Proporsi Kategori — order_status

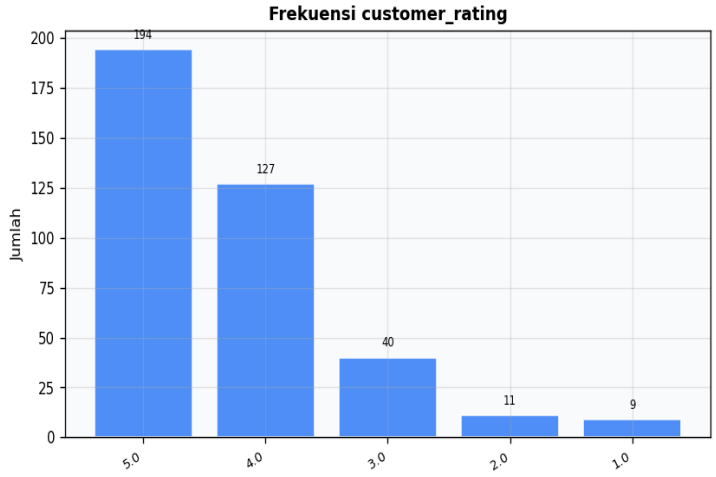


Gambar 38. Proporsi Kategori — order_status

Interpretasi

Pie chart **order_status** menunjukkan proporsi relatif dari 27 kategori. Kategori "DELIVERED" mendominasi dengan 19.8% dari keseluruhan data.

6.40 Frekuensi Kategori — customer_rating

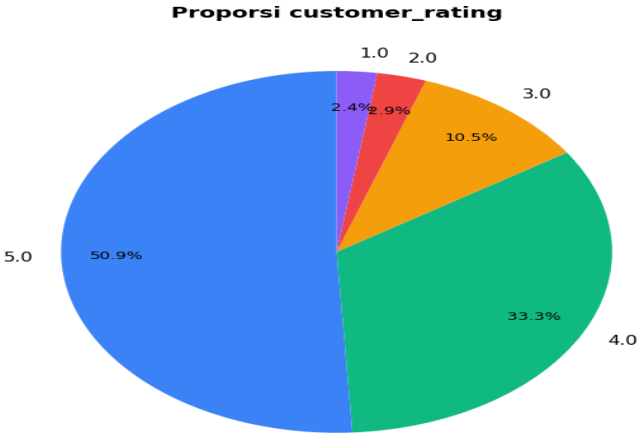


Gambar 39. Frekuensi Kategori — customer_rating

Interpretasi

Variabel **customer_rating** memiliki 5 kategori unik. Kategori terdominan adalah "5.0" dengan proporsi 51.44%.

6.41 Proporsi Kategori — customer_rating

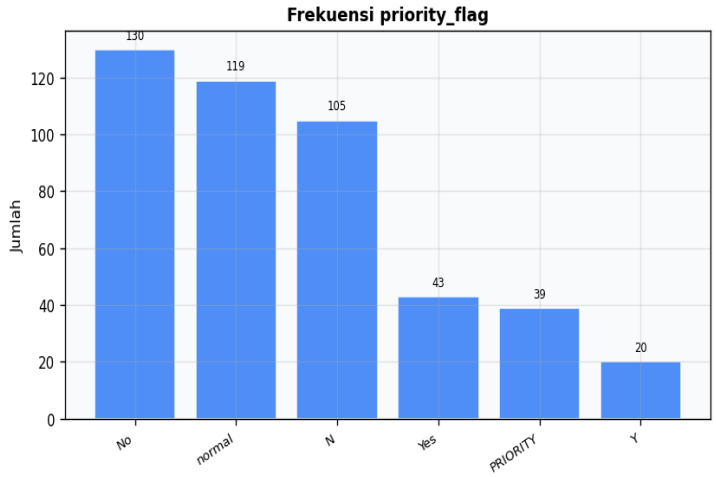


Gambar 40. Proporsi Kategori — customer_rating

Interpretasi

Pie chart **customer_rating** menunjukkan proporsi relatif dari 5 kategori. Kategori "5.0" mendominasi dengan 51.44% dari keseluruhan data.

6.42 Frekuensi Kategori — priority_flag

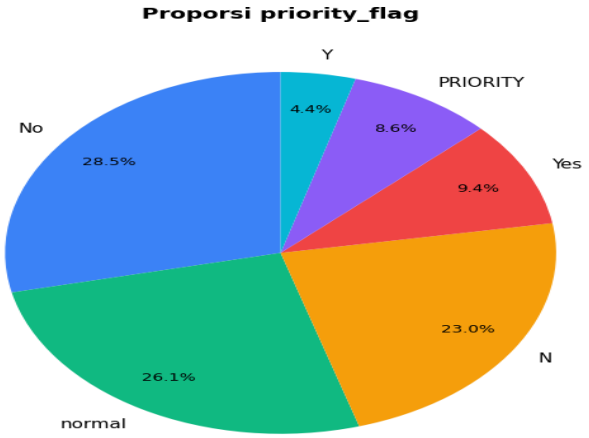


Gambar 41. Frekuensi Kategori — priority_flag

Interpretasi

Variabel **priority_flag** memiliki 6 kategori unik. Kategori terdominan adalah "No" dengan proporsi 26.99%.

6.43 Proporsi Kategori — priority_flag

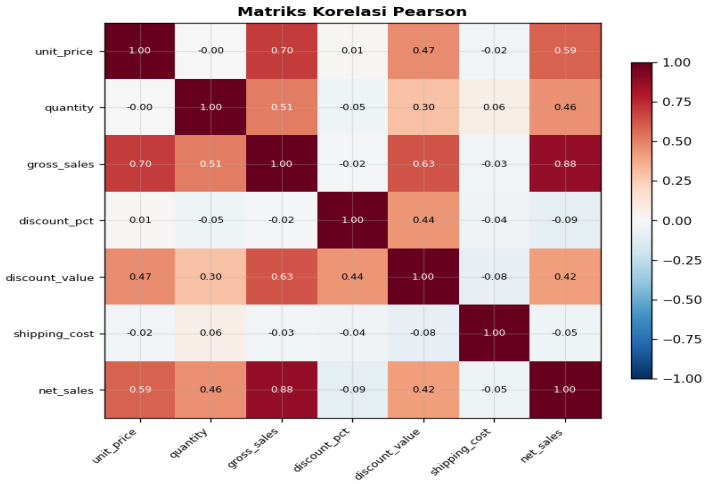


Gambar 42. Proporsi Kategori — priority_flag

Interpretasi

Pie chart **priority_flag** menunjukkan proporsi relatif dari 6 kategori. Kategori "No" mendominasi dengan 26.99% dari keseluruhan data.

6.44 Matriks Korelasi Pearson

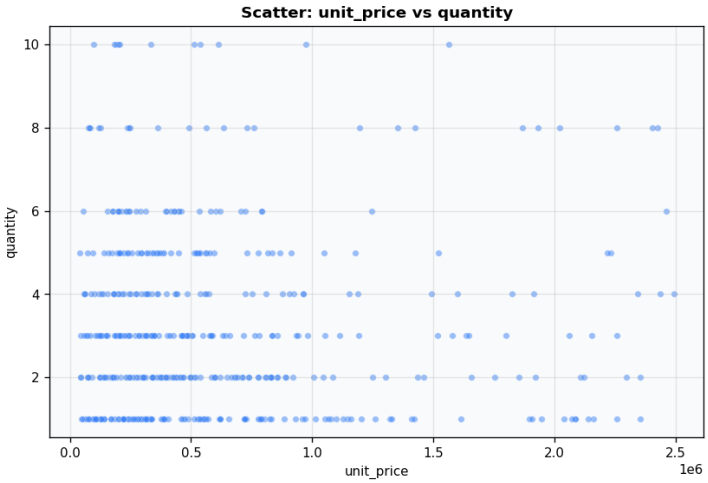


Gambar 43. Matriks Korelasi Pearson

Interpretasi

Heatmap menampilkan matriks korelasi antara variabel numerik: **unit_price, quantity, gross_sales, discount_pct, discount_value**. Nilai korelasi mendekati 1 atau -1 menunjukkan hubungan kuat, mendekati 0 menunjukkan hubungan lemah.

6.45 Scatter Plot: unit_price vs quantity

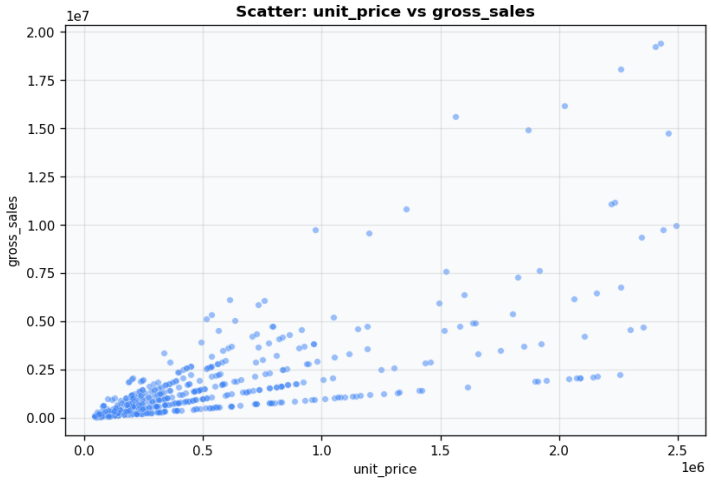


Gambar 44. Scatter Plot: unit_price vs quantity

Interpretasi

Scatter plot antara **unit_price** dan **quantity** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.46 Scatter Plot: unit_price vs gross_sales

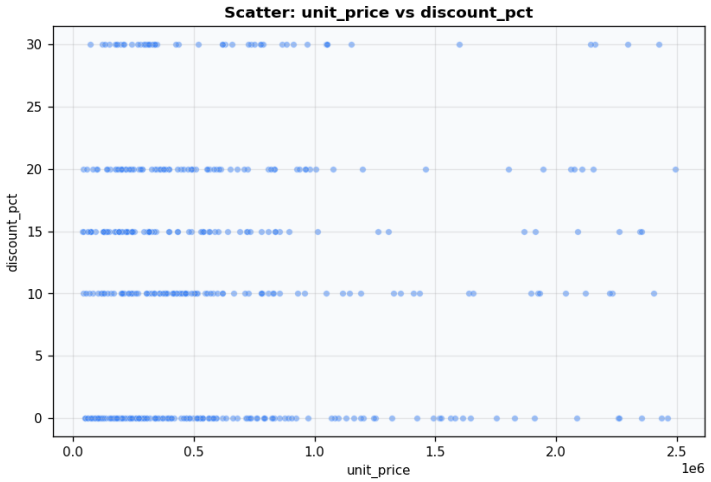


Gambar 45. Scatter Plot: unit_price vs gross_sales

Interpretasi

Scatter plot antara **unit_price** dan **gross_sales** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.47 Scatter Plot: unit_price vs discount_pct

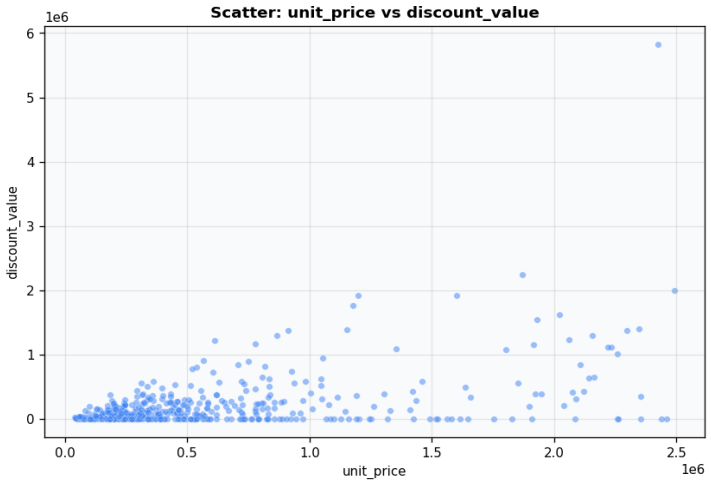


Gambar 46. Scatter Plot: unit_price vs discount_pct

Interpretasi

Scatter plot antara **unit_price** dan **discount_pct** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.48 Scatter Plot: unit_price vs discount_value

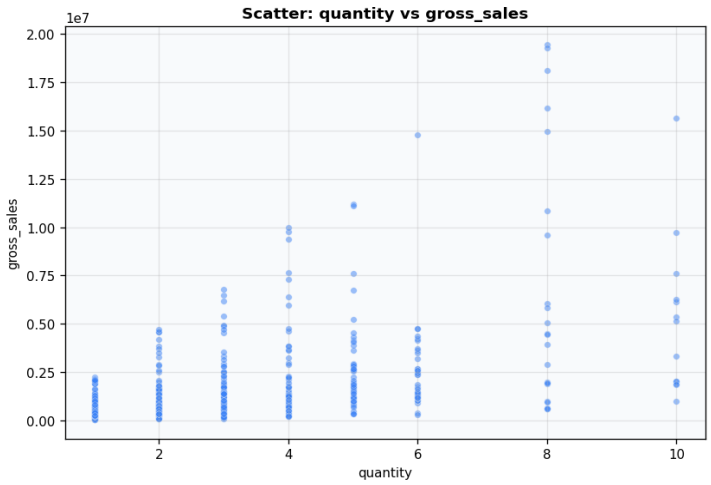


Gambar 47. Scatter Plot: unit_price vs discount_value

Interpretasi

Scatter plot antara **unit_price** dan **discount_value** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.49 Scatter Plot: quantity vs gross_sales

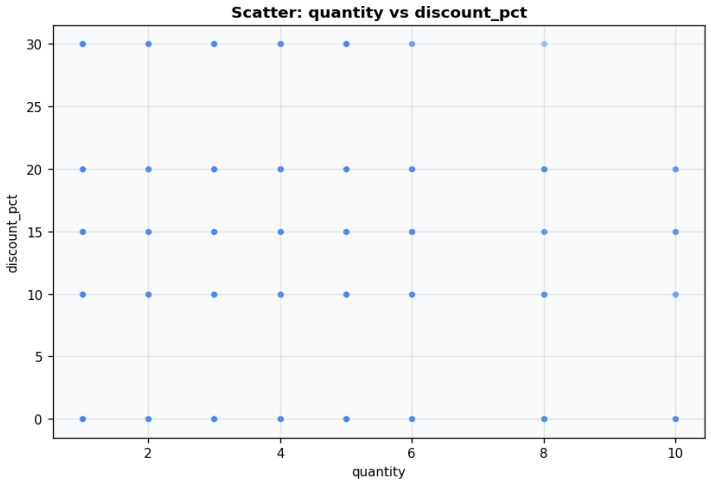


Gambar 48. Scatter Plot: quantity vs gross_sales

Interpretasi

Scatter plot antara **quantity** dan **gross_sales** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.50 Scatter Plot: quantity vs discount_pct

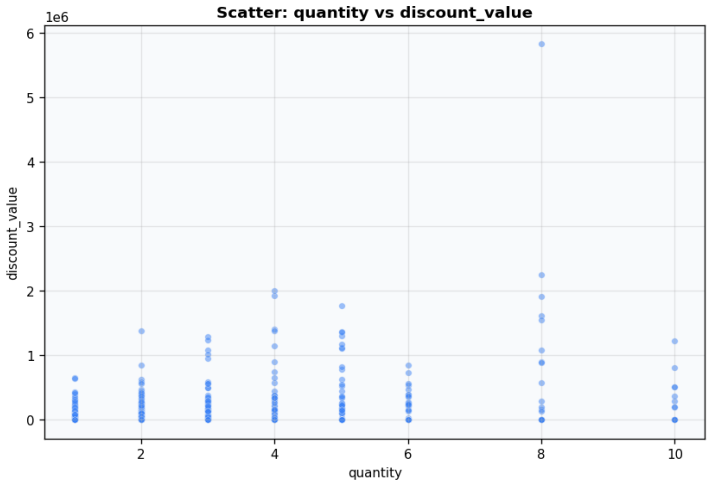


Gambar 49. Scatter Plot: quantity vs discount_pct

Interpretasi

Scatter plot antara **quantity** dan **discount_pct** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.51 Scatter Plot: quantity vs discount_value

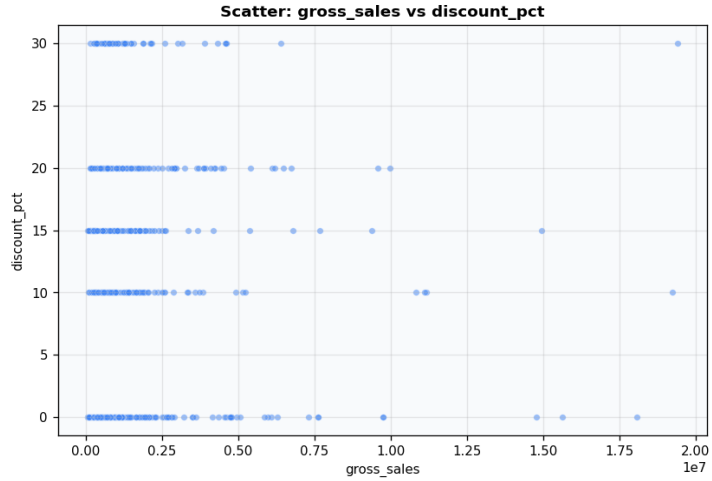


Gambar 50. Scatter Plot: quantity vs discount_value

Interpretasi

Scatter plot antara **quantity** dan **discount_value** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.52 Scatter Plot: gross_sales vs discount_pct



Gambar 51. Scatter Plot: gross_sales vs discount_pct

Interpretasi

Scatter plot antara **gross_sales** dan **discount_pct** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.53 Scatter Plot: gross_sales vs discount_value

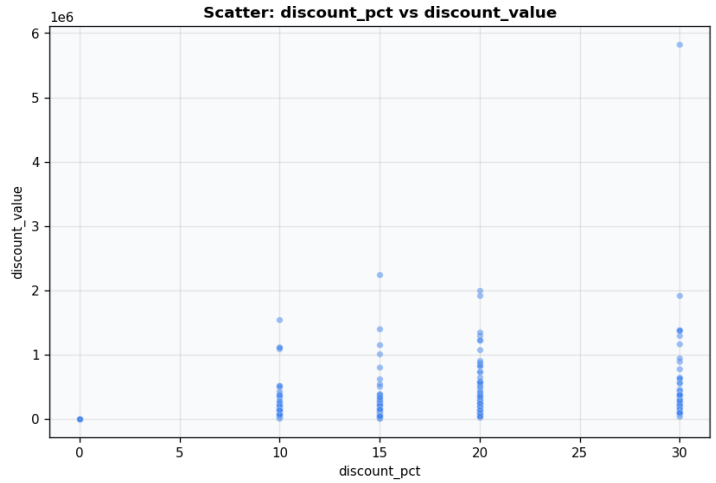


Gambar 52. Scatter Plot: gross_sales vs discount_value

Interpretasi

Scatter plot antara **gross_sales** dan **discount_value** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

6.54 Scatter Plot: discount_pct vs discount_value



Gambar 53. Scatter Plot: discount_pct vs discount_value

Interpretasi

Scatter plot antara **discount_pct** dan **discount_value** menggambarkan hubungan/ko-relasi antara kedua variabel numerik tersebut.

Bab VIII — Proses Data Cleaning

8.1 Gambaran Proses Pembersihan Data

Pembersihan data (*data cleaning*) adalah proses identifikasi dan perbaikan (atau penghapusan) data yang tidak akurat, tidak lengkap, atau tidak konsisten dari dataset. Proses ini krusial karena kualitas output analisis sangat bergantung pada kualitas input data — prinsip "*Garbage In, Garbage Out*" (GIGO).

8.3 Log Proses Pembersihan

Langkah 1: Upload awal (raw data)

Bab IX — Temuan Kunci & Insight Otomatis

9.1 Metodologi Perumusan Insight

Insight dalam laporan ini dirumuskan secara otomatis oleh sistem DS Generator berdasarkan analisis statistik multi-dimensi. Sistem mengidentifikasi pola anomali, korelasi signifikan, distribusi tidak normal, dan karakteristik khusus dataset yang berpotensi memiliki implikasi analitis atau bisnis yang penting.

9.2 Daftar Temuan

■ 1. Missing Values Kecil (2.2%)	Terdapat 947 sel kosong (2.2% dari total data). Tingkat ini masih tergolong aman, namun disarankan melakukan imputasi (mean/median/modus) sebelum pemodelan.
■ 2. Dataset: 2,000 Baris × 22 Kolom	Ukuran dataset cukup representatif untuk analisis statistik yang handal. Terdiri dari 7 kolom numerik dan 14 kolom kategorikal.
■ 3. Nilai Rata-rata Tertinggi: gross_sales	Kolom **gross_sales** memiliki nilai rata-rata tertinggi sebesar **1,748,582.2**. Median: 987813.0, Std: 2316825.4.
✗ 4. Missing Values Terbanyak: customer_rating	Kolom **customer_rating** memiliki missing values terbanyak: **406 baris (20.3%)**. Pertimbangkan imputasi untuk kolom ini.
■ 5. Outlier Terbanyak: net_sales	Kolom **net_sales** memiliki outlier terbanyak: **183 titik data (9.2%)** berdasarkan metode IQR (±1.5×IQR). Tinjau apakah outlier ini merupakan error data atau nilai ekstrem yang valid.
■ 6. Standar Deviasi Terbesar: gross_sales	Kolom **gross_sales** memiliki standar deviasi terbesar sebesar **2,316,825.4025** (CV=132.5%). Variabilitas sangat tinggi pada kolom ini menunjukkan sebaran data yang lebar.
■ 7. Uji Normalitas — 0/7 Kolom Normal	Kolom TIDAK normal: unit_price, quantity, gross_sales (+4 lainnya). Kolom tidak normal (100.0%) memerlukan uji non-parametrik (Mann-Whitney, Kruskal-Wallis) atau transformasi data (log, sqrt, Box-Cox) sebelum analisis parametrik.
■ 8. Distribusi Miring: 5 Kolom	Kolom berikut memiliki skewness > 1: unit_price (skew=1.76), quantity (skew=1.24), gross_sales (skew=3.63), discount_value (skew=7.01). Distribusi miring ini dapat memengaruhi hasil analisis parametrik. Pertimbangkan transformasi log atau Box-Cox.
✓ 9. Keseimbangan Kategorikal (order_date): Seimbang	Distribusi kategori cukup merata. Kategori terbanyak: "2024-09-29" (0.3%). Total 1059 kategori unik pada kolom order_date.

✓ 10. Rekomendasi Analisis Lanjut	Berdasarkan struktur dataset ini, teknik yang disarankan: One-Way ANOVA / T-Test untuk membandingkan rata-rata antar grup kategorikal; Regresi Linear / Logistik untuk prediksi dan pemodelan; Chi-Square + Cramér's V untuk asosiasi antar variabel kategorikal; Uji Non-Parametrik (Mann-Whitney, Spearman) untuk kolom tidak normal; Principal Component Analysis (PCA) untuk reduksi dimensi.

Bab X — Rekomendasi Strategis

10.1 Dasar Perumusan Rekomendasi

Rekomendasi berikut dirumuskan berdasarkan temuan dari analisis kualitas data, statistik deskriptif, and insight otomatis yang dihasilkan. Setiap rekomendasi bersifat spesifik dan dapat ditindaklanjuti (*actionable*) oleh tim data atau pemangku kepentingan terkait.

10.2 Daftar Rekomendasi

R1. Penanganan Missing Values	Dataset memiliki 947 sel kosong. Disarankan untuk mengisi nilai kosong menggunakan imputasi mean/median untuk variabel numerik dan modus untuk variabel kategorikal. Jika proporsi missing values melebihi 50% pada suatu kolom, pertimbangkan untuk menghapus kolom tersebut dari analisis.
R2. Pembersihan Duplikat	Ditemukan 9 baris duplikat yang berpotensi menghasilkan bias dalam analisis. Lakukan deduplication dengan mempertahankan satu observasi per grup duplikat, atau terapkan primary key constraint pada database sumber untuk mencegah duplikasi di masa depan.
R3. Investigasi & Penanganan Outlier	Terdeteksi 139 nilai outlier menggunakan metode IQR. Lakukan validasi domain untuk memverifikasi apakah nilai ekstrem tersebut valid secara konteks bisnis atau merupakan kesalahan pencatatan. Jika terbukti error, terapkan IQR capping (winsorization) untuk menetralkan dampaknya.
R4. Transformasi Data Skewed	Variabel unit_price, quantity, gross_sales, discount_value memiliki distribusi yang sangat miring (|skewness| > 1). Pertimbangkan transformasi logaritmik, akar kuadrat, atau Box-Cox sebelum digunakan dalam pemodelan statistik untuk memenuhi asumsi normalitas.
R5. Pembersihan Data Berkala	Jadwalkan audit kualitas data secara berkala menggunakan DS Generator sebelum setiap siklus analisis. Dokumentasikan setiap keputusan cleaning untuk memastikan reproducibility dan transparansi proses analisis.
R6. Eksplorasi Analisis Lanjutan	Setelah pembersihan data selesai, lanjutkan ke analisis korelasi mendalam, pengujian hipotesis statistik, dan pemodelan prediktif jika relevan dengan tujuan bisnis. Dataset yang bersih adalah fondasi untuk model machine learning yang akurat dan andal.

Bab XI — Penutup

11.1 Kesimpulan

Laporan analisis data eksplorasi ini telah berhasil menyajikan gambaran komprehensif terhadap dataset **ecommerce.txt**. Dari total **2,000 observasi** dengan **22 variabel** yang dianalisis, diperoleh beberapa temuan utama: (1) terdapat 947 sel kosong yang perlu ditangani, (2) ditemukan 9 baris duplikat, (3) terdeteksi 139 nilai outlier yang memerlukan verifikasi, dan (4) seluruh variabel telah berhasil diklasifikasikan berdasarkan tipe datanya untuk analisis lebih lanjut.

10.2 Keterbatasan

Laporan ini memiliki beberapa keterbatasan yang perlu diperhatikan: (1) Analisis ini bersifat deskriptif dan tidak mencakup inferensi statistik atau pemodelan prediktif; (2) Kualitas insight yang dihasilkan bergantung pada kelengkapan dan representativitas data yang diunggah; (3) Interpretasi otomatis mungkin tidak selalu mencerminkan konteks domain bisnis yang spesifik dan perlu dikonfirmasi oleh pakar domain terkait.

10.3 Penutup

Demikian laporan analisis data ini disusun. Kami berharap temuan dan rekomendasi yang tersaji dapat memberikan kontribusi nyata dalam mendukung proses pengambilan keputusan yang berbasis data. Platform DS Generator terus dikembangkan untuk menghadirkan fitur analisis yang semakin canggih dan mudah digunakan.

Laporan ini digenerate secara otomatis oleh DS Generator pada 26 June 2026, 15:57:32.