DS GENERATOR

Laporan Analisis Data Deskriptif

Exploratory Data Analysis Report

Institut Teknologi Sains Bandung — Kelompok 2

DATASET	TOTAL DATA	STATUS	TANGGAL	ANALIS
02_data.xlsx	1,826 baris x 6 kolom	RAW DATA — Perlu Pembersihan	05 July 2026	Kelompok 2 ITSB

Auto-generated by DS Generator Platform

Bab I — Kata Pengantar

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas segala berkat dan rahmat-Nya sehingga laporan analisis data ini dapat diselesaikan dengan baik. Laporan ini merupakan hasil analisis eksplorasi data (*Exploratory Data Analysis*) yang dilakukan secara otomatis menggunakan platform **DS Generator** — sistem analisis data deskriptif berbasis web yang dikembangkan oleh **Kelompok 2**, Program Studi Data Science, Institut Teknologi Sains Bandung (ITSB).

Laporan ini menyajikan analisis menyeluruh terhadap dataset **02_data.xlsx** yang terdiri dari **1,826 baris observasi** dan **6 variabel**. Berdasarkan hasil pemindaian kualitas data yang dilakukan secara otomatis, dataset ini memerlukan proses pembersihan data lebih lanjut karena ditemukan 0 sel kosong dan 0 baris duplikat. Sebanyak 96 potensi outlier juga terdeteksi melalui metode IQR.

Laporan ini disusun dengan tujuan untuk memberikan gambaran komprehensif dan terstruktur mengenai karakteristik data, distribusi variabel, kualitas data, serta temuan-temuan penting yang dapat dijadikan dasar pengambilan keputusan berbasis data (*data-driven decision making*). Analisis yang disajikan meliputi statistik deskriptif, visualisasi distribusi, deteksi anomali, serta rekomendasi strategis yang dirumuskan secara otomatis berdasarkan pola data yang teridentifikasi.

Kami menyadari bahwa laporan ini masih memiliki keterbatasan, terutama dalam hal kedalaman analisis yang bergantung pada kelengkapan dan kualitas data yang diberikan. Oleh karena itu, saran dan masukan yang konstruktif sangat kami harapkan demi penyempurnaan di masa mendatang. Semoga laporan ini dapat memberikan nilai tambah yang signifikan bagi pembaca dan pihak-pihak yang memerlukan informasi dari dataset ini.

Cikarang, 05 July 2026

Tim Penyusun,

Kelompok 2 — Data Science Programming

Institut Teknologi Sains Bandung (ITSB)

Bab II — Pendahuluan & Latar Belakang

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mendorong munculnya ledakan data (*data explosion*) di berbagai sektor industri dan akademik. Kemampuan untuk memahami, mengolah, dan menginterpretasikan data secara efisien menjadi kompetensi krusial di era transformasi digital ini. Analisis data eksplorasi (*Exploratory Data Analysis* — EDA) merupakan langkah fundamental yang harus dilakukan sebelum pemodelan statistik atau machine learning, guna memahami karakteristik dasar dataset, mendeteksi anomali, dan merumuskan hipotesis awal yang akan diuji lebih lanjut.

Dataset **02_data.xlsx** yang dianalisis dalam laporan ini merupakan data dengan 1,826 observasi dan 6 variabel. Keberagaman variabel yang mencakup 3 variabel numerik dan 2 variabel kategorikal memberikan peluang analisis yang komprehensif untuk mengungkap pola tersembunyi dalam data.

1.2 Tujuan Analisis

- Mengidentifikasi karakteristik statistik dasar setiap variabel dalam dataset.
- Mendeteksi dan mengkuantifikasi masalah kualitas data (missing values, duplikat, outlier).
- Menganalisis distribusi dan pola sebaran data pada variabel numerik dan kategorikal.
- Menghasilkan visualisasi data yang informatif dan mudah dipahami.
- Merumuskan rekomendasi strategis berdasarkan temuan analisis.

1.3 Ruang Lingkup

Analisis dalam laporan ini mencakup: (1) pemeriksaan kualitas dan kesehatan data, (2) statistik deskriptif untuk seluruh variabel numerik dan kategorikal, (3) deteksi outlier menggunakan metode Interquartile Range (IQR), (4) analisis korelasi antar variabel numerik, serta (5) pembersihan data jika diperlukan. Analisis prediktif atau inferensial berada di luar ruang lingkup laporan ini.

1.4 Metodologi

Analisis dilakukan menggunakan platform **DS Generator** yang dibangun di atas ekosistem Python dengan library utama: **Pandas** untuk manipulasi data, **NumPy** untuk komputasi numerik, **Plotly** untuk visualisasi interaktif, **SciPy** untuk uji statistik, dan **ReportLab** untuk generasi laporan PDF. Proses analisis berjalan secara otomatis (*automated pipeline*) setelah dataset diunggah ke dalam sistem.

Bab III — Deskripsi & Ringkasan Dataset

2.1 Ringkasan Eksekutif

1,826	6	0	0	96
Total Baris	Total Kolom	Missing Values	Duplikat	IQR Outliers

Dataset **02_data.xlsx** terdiri dari **1,826 observasi** dengan **6 variabel**. Tidak ditemukan sel kosong pada dataset ini. Deteksi outlier menggunakan metode IQR menemukan **96 potensi nilai ekstrem** yang perlu diverifikasi lebih lanjut.

2.2 Komposisi Variabel

Tipe Variabel	Jumlah	Contoh Variabel
Numerik (Kuantitatif)	3	Rainfall_mm, TSS_mg_L, Flow
Kategorikal (Kualitatif)	2	Location, Activity

Tabel 1. Komposisi variabel berdasarkan tipe data

Bab IV — Kualitas Data & Data Health

3.1 Gambaran Umum Kualitas Data

Pemeriksaan kualitas data (*data quality assessment*) merupakan langkah krusial sebelum analisis statistik dilakukan. Pada tahap ini, setiap kolom diperiksa untuk mengidentifikasi sel kosong, nilai duplikat, inkonsistensi format, dan nilai ekstrem yang dapat mempengaruhi keakuratan analisis.

3.2 Detail Kualitas per Kolom

Kolom	Tipe	Missing	Unique	Outliers	Status
Date	datetime64[us]	0 (0.0%)	1826	0	■ Warning
Location	str	0 (0.0%)	3	0	✓ OK
Rainfall_mm	float64	0 (0.0%)	294	69	■ Warning
TSS_mg_L	float64	0 (0.0%)	1073	27	■ Warning
Flow	int64	0 (0.0%)	140	0	✓ OK
Activity	str	0 (0.0%)	3	0	✓ OK

Tabel 2. Ringkasan kualitas data per kolom

3.3 Peringatan Kualitas Data

Sistem mendeteksi sejumlah isu kualitas data yang perlu ditangani sebelum analisis lebih lanjut dilakukan:

- 96 outlier terdeteksi (metode IQR)
- 1 kolom kemungkinan tidak relevan (ID/free text)

Bab V — Statistik Deskriptif — Variabel Numerik

4.1 Pengertian Statistik Deskriptif

Statistik deskriptif adalah cabang statistik yang bertujuan merangkum, mendeskripsikan, dan menyajikan data secara informatif tanpa menarik kesimpulan inferensial. Ukuran yang digunakan meliputi: **Mean** (rata-rata aritmatik), **Median** (nilai tengah), **Standar Deviasi** (ukuran dispersi/keragaman), **Nilai Minimum dan Maksimum** (rentang data), serta **Kuartil** (Q25 dan Q75) yang membagi data menjadi empat bagian sama besar.

4.2 Tabel Statistik Deskriptif

Kolom	Count	Missing	Mean	Median	Std Dev	Min	Q25	Q75	Max	Skewness
Rainfall_mm	—	—	9.91	8.3	7.02	0.1	—	—	47.8	1.3774
TSS_mg_L	—	—	89.04	74.95	50.58	10.0	—	—	291.8	0.9738
Flow	—	—	147.52	148.0	40.75	80.0	—	—	219.0	0.0467

Tabel 3. Statistik deskriptif variabel numerik

4.3 Interpretasi per Variabel

4.3.1 Variabel: Rainfall_mm

Variabel **Rainfall_mm** memiliki nilai rata-rata sebesar **9.91** dengan nilai tengah (median) **8.3**. Distribusi data miring ke kanan (*right-skewed*, skewness = 1.3774), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **0.1** hingga **47.8** dengan standar deviasi **7.02**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.2 Variabel: TSS_mg_L

Variabel **TSS_mg_L** memiliki nilai rata-rata sebesar **89.04** dengan nilai tengah (median) **74.95**. Distribusi data miring ke kanan (*right-skewed*, skewness = 0.9738), artinya terdapat beberapa nilai ekstrem tinggi yang menarik rata-rata ke atas. Rentang nilai berkisar antara **10.0** hingga **291.8** dengan standar deviasi **50.58**. Nilai standar deviasi yang relatif besar mengindikasikan variabilitas data yang tinggi, sehingga perlu dilakukan investigasi lebih lanjut terhadap penyebab keragaman nilai tersebut.

4.3.3 Variabel: Flow

Variabel **Flow** memiliki nilai rata-rata sebesar **147.52** dengan nilai tengah (median) **148.0**. Distribusi data cenderung simetris (|skewness| < 0,5), mengindikasikan data mendekati distribusi normal. Rentang nilai berkisar antara **80.0** hingga **219.0** dengan standar deviasi **40.75**. Nilai standar deviasi yang relatif kecil menunjukkan data cukup homogen dan konsisten.

Bab VI — Statistik Deskriptif — Variabel Kategorikal

5.1 Pengertian Variabel Kategorikal

Variabel kategorikal adalah variabel yang nilainya berupa kategori atau label, bukan angka kontinu. Terdapat dua jenis utama: variabel **nominal** (kategori tanpa urutan, misal: jenis kelamin, kota) dan variabel **ordinal** (kategori berurutan, misal: tingkat kepuasan, kelas nilai). Analisis variabel kategorikal berfokus pada frekuensi kemunculan setiap kategori dan distribusi proporsionalnya.

5.2 Tabel Statistik Kategorikal

Kolom	Unique	Mode (Dominan)	Frekuensi Mode	Mode %	Missing
Location	3	Outlet_A	634	34.72%	0
Activity	3	Normal Operation	1319	72.23%	0

Tabel 4. Statistik deskriptif variabel kategorikal

5.3 Interpretasi per Variabel

5.3.1 Variabel: Location

Variabel kategorikal **Location** memiliki **3 kategori unik**. Kategori yang paling dominan adalah "**Outlet_A**" dengan frekuensi kemunculan sebesar **34.72%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation.

5.3.2 Variabel: Activity

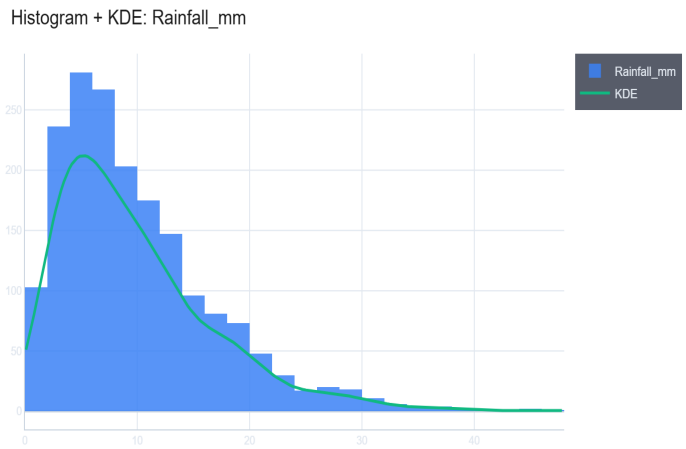
Variabel kategorikal **Activity** memiliki **3 kategori unik**. Kategori yang paling dominan adalah "**Normal Operation**" dengan frekuensi kemunculan sebesar **72.23%%** dari total data. Jumlah kategori yang sedikit menunjukkan variabel ini bersifat ordinal atau nominal terbatas, cocok untuk analisis frekuensi dan cross-tabulation.

Bab VII — Visualisasi Data & Interpretasi

6.1 Pentingnya Visualisasi dalam EDA

Berikut adalah visualisasi kunci yang dihasilkan secara otomatis dari dataset ini, dipilih berdasarkan relevansi statistik (variabilitas, skewness, dan distribusi kategori) untuk mendukung interpretasi data.

6.2 Distribusi Frekuensi — Rainfall_mm

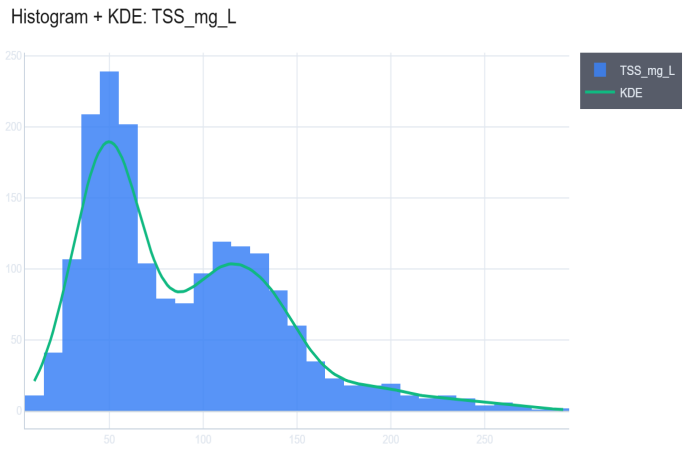


Interpretasi

Variabel **Rainfall_mm** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 1.3774) dengan rata-rata 9.91.

Gambar 1. Distribusi Frekuensi — Rainfall_mm

6.3 Distribusi Frekuensi — TSS_mg_L

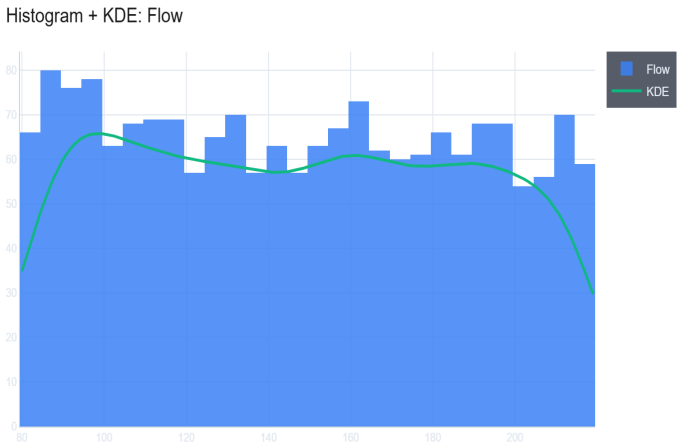


Interpretasi

Variabel **TSS_mg_L** menunjukkan distribusi miring ke kanan (right-skewed) (skewness = 0.9738) dengan rata-rata 89.04.

Gambar 2. Distribusi Frekuensi — TSS_mg_L

6.4 Distribusi Frekuensi — Flow

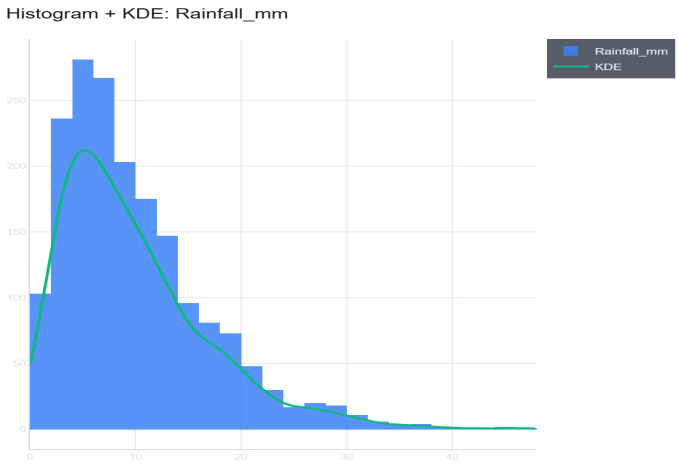


Interpretasi

Variabel **Flow** menunjukkan distribusi cenderung simetris (skewness = 0.0467) dengan rata-rata 147.52.

Gambar 3. Distribusi Frekuensi — Flow

6.5 Matriks Korelasi Pearson

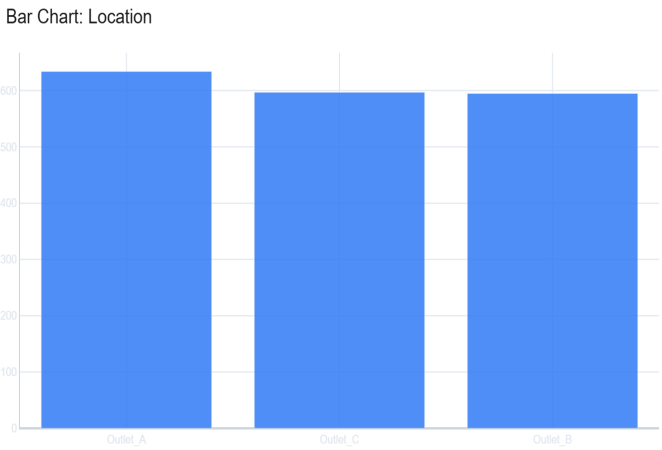


Interpretasi

Heatmap menampilkan matriks korelasi antara variabel numerik: **Rainfall_mm, TSS_mg_L, Flow**. Nilai korelasi mendekati 1 atau -1 menunjukkan hubungan kuat, mendekati 0 menunjukkan hubungan lemah.

Gambar 4. Matriks Korelasi Pearson

6.6 Frekuensi Kategori — Location

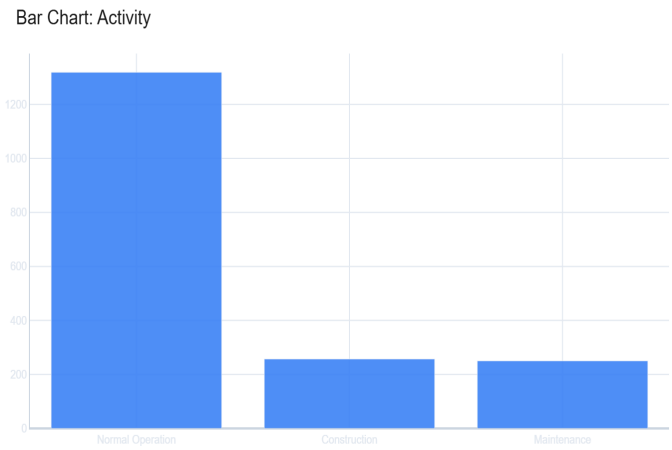


Interpretasi

Variabel **Location** memiliki 3 kategori unik. Kategori terdominan adalah "Outlet_A" dengan proporsi 34.72%.

Gambar 5. Frekuensi Kategori — Location

6.7 Frekuensi Kategori — Activity



Gambar 6. Frekuensi Kategori — Activity

Interpretasi

Variabel **Activity** memiliki 3 kategori unik. Kategori terdominan adalah "Normal Operation" dengan proporsi 72.23%.

Bab VIII — Proses Data Cleaning

7.1 Gambaran Proses Pembersihan Data

Pembersihan data (*data cleaning*) adalah proses identifikasi dan perbaikan (atau penghapusan) data yang tidak akurat, tidak lengkap, atau tidak konsisten dari dataset. Proses ini krusial karena kualitas output analisis sangat bergantung pada kualitas input data — prinsip "*Garbage In, Garbage Out*" (GIGO).

7.2 Perbandingan Sebelum & Sesudah Cleaning

Metrik	Sebelum	Sesudah	Perubahan
Jumlah Baris	1826	1826	Δ 0 baris
Jumlah Kolom	6	6	Δ 0 kolom
Sel Kosong	0	0	Berkurang 0 sel

Tabel 5. Perbandingan dataset sebelum dan sesudah cleaning

7.3 Log Proses Cleaning

Langkah 1: Upload awal (raw data)

Bab IX — Temuan Kunci & Insight Otomatis

8.1 Metodologi Perumusan Insight

Insight dalam laporan ini dirumuskan secara otomatis oleh sistem DS Generator berdasarkan analisis statistik multi-dimensi. Sistem mengidentifikasi pola anomali, korelasi signifikan, distribusi tidak normal, dan karakteristik khusus dataset yang berpotensi memiliki implikasi analitis atau bisnis yang penting.

8.2 Daftar Temuan

✓ 1. Excellent Data Quality — Zero Missing Values	No missing values found at all. The dataset is clean and ready for statistical analysis or machine learning without additional preprocessing.
■ 2. Dataset: 1,826 Rows × 6 Columns	Dataset size is sufficiently representative for reliable statistical analysis. Consists of 3 numeric and 2 categorical columns.
■ 3. Highest Average Value: Flow	Column **Flow** has the highest average value of **147.52**. Median: 148.0, Std: 40.75.
■ 4. Most Outliers: Rainfall_mm	Column **Rainfall_mm** has the most outliers: **69 data points (3.8%)** based on IQR method (±1.5×IQR). Check whether these outliers are data errors or valid extreme values.
■ 5. Highest Std Deviation: TSS_mg_L	Column **TSS_mg_L** has the largest standard deviation of **50.5798** (CV=56.8%). Very high variability on this column indicates a wide data spread.
■ 6. Normality Test — 0/3 Columns Normal	NOT normal columns: Rainfall_mm, TSS_mg_L, Flow. Non-normal columns (100.0%) require non-parametric tests (Mann-Whitney, Kruskal-Wallis) or data transformation (log, sqrt, Box-Cox) before parametric analysis.
■ 7. Skewed Distributions: 1 Column(s)	The following columns have skewness > 1: Rainfall_mm (skew=1.38). These skewed distributions can affect parametric analysis results. Consider log or Box-Cox transformation.
✓ 8. Categorical Balance (Location): Balanced	Category distribution is fairly even. Most frequent category: "Outlet_A" (34.7%). Total 3 unique categories in column Location.
■ 9. Trend: Meningkat (Upward)	Variabel Rainfall_mm menunjukkan tren meningkat (upward) dengan slope=0.0001 per periode (Daily). R^2=0.000 — tren belum signifikan (p>=0.05).
■ 10. Volatilitas: Tinggi (CV>30%)	Koefisien variasi (CV) = 70.8%. Nilai ini menunjukkan tingkat fluktuasi yang tinggi (cv>30%) pada Rainfall_mm sepanjang periode waktu.
■ 11. Peak & Trough — Rainfall_mm	Nilai tertinggi: 47.80 pada 2023-09-17. Nilai terendah: 0.10 pada 2021-08-02. Range: 47.70.

■ 12. Tidak Ada Pola Musiman Jelas	Tidak ditemukan autocorrelation signifikan pada lag standar (7, 12, 30). Data Rainfall_mm tampak tidak memiliki pola musiman yang kuat.
✓ 13. Further Analysis Recommendations	Based on the structure of this dataset, suggested techniques: One-Way ANOVA / T-Test to compare means across categorical groups; Linear / Logistic Regression for prediction and modeling; Chi-Square + Cramér's V for categorical variable association; Non-Parametric Tests (Mann-Whitney, Spearman) for non-normal columns; Principal Component Analysis (PCA) for dimensionality reduction.

Bab X — Rekomendasi Strategis

9.1 Dasar Perumusan Rekomendasi

Rekomendasi berikut dirumuskan berdasarkan temuan dari analisis kualitas data, statistik deskriptif, dan insight otomatis yang dihasilkan. Setiap rekomendasi bersifat spesifik dan dapat ditindaklanjuti (*actionable*) oleh tim data atau pemangku kepentingan terkait.

9.2 Daftar Rekomendasi

R3. Investigasi & Penanganan Outlier	Terdeteksi 96 nilai outlier menggunakan metode IQR. Lakukan validasi domain untuk memverifikasi apakah nilai ekstrem tersebut valid secara konteks bisnis atau merupakan kesalahan pencatatan. Jika terbukti error, terapkan IQR capping (winsorization) untuk menetralkan dampaknya.
R4. Transformasi Data Skewed	Variabel Rainfall_mm memiliki distribusi yang sangat miring (|skewness| > 1). Pertimbangkan transformasi logaritmik, akar kuadrat, atau Box-Cox sebelum digunakan dalam pemodelan statistik untuk memenuhi asumsi normalitas.
R3. Pembersihan Data Berkala	Jadwalkan audit kualitas data secara berkala menggunakan DS Generator sebelum setiap siklus analisis. Dokumentasikan setiap keputusan cleaning untuk memastikan reproducibility dan transparansi proses analisis.
R4. Eksplorasi Analisis Lanjutan	Setelah pembersihan data selesai, lanjutkan ke analisis korelasi mendalam, pengujian hipotesis statistik, dan pemodelan prediktif jika relevan dengan tujuan bisnis. Dataset yang bersih adalah fondasi untuk model machine learning yang akurat dan andal.

Bab XI — Penutup

10.1 Kesimpulan

Laporan analisis data eksplorasi ini telah berhasil menyajikan gambaran komprehensif terhadap dataset **02_data.xlsx**. Dari total **1,826 observasi** dengan **6 variabel** yang dianalisis, diperoleh beberapa temuan utama: (1) dataset tidak memiliki missing values, (2) tidak ditemukan duplikasi data, (3) terdeteksi 96 nilai outlier yang memerlukan verifikasi, dan (4) seluruh variabel telah berhasil diklasifikasikan berdasarkan tipe datanya untuk analisis lebih lanjut.

10.2 Keterbatasan

Laporan ini memiliki beberapa keterbatasan yang perlu diperhatikan: (1) Analisis ini bersifat deskriptif dan tidak mencakup inferensi statistik atau pemodelan prediktif; (2) Kualitas insight yang dihasilkan bergantung pada kelengkapan dan representativitas data yang diunggah; (3) Interpretasi otomatis mungkin tidak selalu mencerminkan konteks domain bisnis yang spesifik dan perlu dikonfirmasi oleh pakar domain terkait.

10.3 Penutup

Demikian laporan analisis data ini disusun. Kami berharap temuan dan rekomendasi yang tersaji dapat memberikan kontribusi nyata dalam mendukung proses pengambilan keputusan yang berbasis data. Platform DS Generator terus dikembangkan untuk menghadirkan fitur analisis yang semakin canggih dan mudah digunakan.

Laporan ini digenerate secara otomatis oleh DS Generator pada 05 July 2026, 09:11:33.